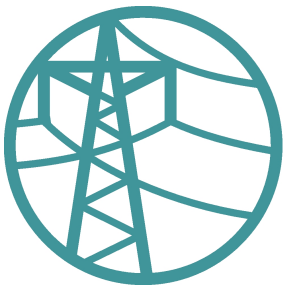

WYDZIAŁ
ELEKTROTECHNIKI
I INFORMATYKI
POLITECHNIKI RZESZOWSKIEJ

inż. Krzysztof Lang

Implementacja wybranych algorytmów wypełniania brakujących wartości, dla strumieni dużych zbiorów danych

Praca dyplomowa magisterska

Opiekun pracy:
dr Michał Piętal

Rzeszów, 2023

Spis treści

1. Wstęp

W pracy opisano znaczenie wypełniania brakujących wartości w dużych zbiorach danych. Przedstawiono 3 algorytmy służące wypełnianiu brakujących danych, które następnie zostały zaimplementowane z użyciem stworzonej na te potrzeby aplikacji. Dokonano porównania dokładności wypełniania danych dla poszczególnych algorytmów i przeanalizowano uzyskane wyniki. Do przygotowania aplikacji wykorzystano język programowania Python [1], z wykorzystaniem bibliotek służących do analiz i manipulacji danymi: Pandas [2], NumPy [3] i SciKit-learn [4] oraz biblioteki udostępniającej narzędzia do przygotowania interfejsu graficznego EasyGUI [5]. Dane wykorzystane do testów pochodzą z repozytorium danych do uczenia maszynowego Uniwersytetu Kalifornijskiego w Irvine [6] oraz zbioru baz danych udostępnionych w serwisie Kaggle.com [7].

W pierwszym rozdziale przedstawiono zarys treści dalszej pracy. W drugim rozdziale przybliżono ideę wypełniania brakujących wartości w duzych zbiorach danych, na co składa się rys historyczny zagadnienia, przedstawienie istniejących rozwiązań i ich znaczenie, oraz zastanowiono się nad przyszłością zagadnienia. Trzeci rozdział przybliża narzędzia użyte do przygotowania części praktycznej niniejszej pracy, to jest programu realizującego testy algorytmów wypełniajacych puste miejsca oraz dane wykorzystane do testów. Na rodział czwarty składa się opis praktycznej części badań. Znajduje się w nim opis przygotowanego programu wraz z przykładem działana, opisy zaimplementowanych algorytmów, oraz przedstawione zostały wyniki przeprowadzonych testów. Rozdział piąty składa się z podsumowania przeprowadzonych analiz i przedstawienia wyciągniętych wniosków.

2. Wprowadzenie

2.1. Problematyka wypełniania brakujących wartości

Brakujące wartości są częstym problemem występującym w wielu dziedzinach, szczególnie tych operujacych na dużych bazach danych. Utrudniają one analizę zebranych informacji, pogarszając wartość danych. Przykładowe rodzaje danych dla których może to mieć znaczenie to między innymi:

- dane finansowe, gdzie dane wykorzystywane są między innymi do przewidywania zachowania rynków, [8]
- dane medyczne, gdzie dane wykorzystywane są między innymi do pracy nad nowymi lekami i terapiami, [9]
- dane statystyczne dotyczące populacji, których analiza może być wykorzystana do planowania inwestycji w miastach, [10]
- dane o ruchu sieciowym, mogące posłużyć do wykrywania problemów w sieci czy zapobiegania atakom. [11]

Powyższe przykłady to tylko drobny wycinek potencjalnych zastosowań analizy dużych zbiorów danych, dla których jej dokładność jest kluczowa.

Braki w danych mogą występować z różnych powodów, mogą pojawiać się zarówno podczas samego zbierania danych jak i później. Przykładowymi źródłami brakujących danych są:

- błędy w sposobie zbierania danych,
- niepoprawnie zaprojektowana baza danych,
- uszkodzenie nośnika danych,
- błędy wynikające z niepoprawnego importu danych,
- czynnik ludzki,
- uszkodzone instrumenty zbierające dane.

Brakujące dane można zakwalifikować do jednego z 3 typów [12]:

1) MCAR (ang. missing completly at random) – brakujące w pełni losowo. Oznacza to, że brakujące wartości rozmieszczone są losowo, bez powiązania z innymi danymi.

2) MAR (ang. missing at random) – brakujące losowo. Takie dane rozmieszczone są losowo, lecz widoczne jest powiązanie z innymi danymi.

3) MNAR (ang. missing not at random) – brakujące w sposób nielosowy. Oznacza to, że brakujące wartości można powiązać z innymi danymi.

Historia prób wypełniania brakujących wartości sięga wczesnych lat XX wieku. Wtedy statystycy tacy jak Ronald Fisher i Edwin Wilson zaproponowali metody oparte o średnią i medianę rozpatrywanych danych. Te metody są stosowane do dziś w niektórych przypadkach, na przykład gdy dane zaliczają się do kategorii MCAR. [13][14]

Dużym przełomem dla wypełniania brakujących danych była publikacja pracy Donalda Rubina pod koniec XX wieku. Zaprezentowano w niej koncept wielokrotnej imputacji (MI, ang. multiple imputation). Polega on na generowaniu kilku zestawów danych z imputowanymi wartościami na podstawie rozkładu wielowymiarowego danych. Następnie stosuje się metodę statystyczną do każdego zestawu danych i łączy się wyniki, aby uzyskać oszacowania parametrów i ich błędy. [15]

Od tego czasu medoda wielokrotnej imputacji stała się populkarnym sposobem uzupełniania brakujących danych w wielu dziedzinach. [16]

2.2. Korzyści i zagrożenia

Różne metody wypełniania są przydatne dla różnych zastosowań. Wśród nich jest zwiększanie jakości danych, ułatwienie bądź umożliwienie przeprowadzenia analizy danych, zwiększenie wydajności systemów korzystających z danych. Należy jednak mieć na uwadze potencjalne zagrożenia wynikające ze sztucznego tworzenia danych, jak to ma miejsce w przypadku wypełniania. Aby zminimalizować ryzyko pogorszenia zamiast poprawienia jakości zbioru danych należy dostosować wykorzystane metody do charakteru danych. Należy brać pod uwagę:

- ilość brakujących danych – bardzo duże braki mogą nawet uniemożliwić poprawne wypełnianie,

- rodzaj danych – przykładowo dane liczbowe wymagają zastosowania innych metod niż kategoryczne,
- źródło danych – dane zebrane przez przyrządy pomiarowe znacząco różnią się od danych zebranych w ramach ankiety.

2.3. Perspektywy na przyszłość

Aktualne trendy wskazują, że metody wypełniania zbiorów danych będą zyskiwały na znaczeniu. Wynika to z rosnącego znaczenia zbierania i analizowania danych. Coraz więcej branż zaczyna opierać swoje działania na analizie danych z różnych źródeł. Tworzone, przechowywane i analizowane są ogromne zbiory danych o różnym przeznaczeniu, tak zwane Big Data. [18] Uruchamiane są przedsięwzięcia Open Government Data, polegające na udostępnianiu przez organy administracji publicznej swoich zbiorów danych. [19] [20]

Większa ilość danych oznacza większą ilość braków. Większa ilość braków wymusza tworzenie nowych, dokładniejszych i szybszych metod ich wypełniania. Przewidywane kierunki rozwoju algorytmów wypełniania obejmują: [21]

- nowe, bardziej zaawansowane metody wypełniania, tworzone z myślą o konkretnych typach danych,
- zwiększanie integracji z innymi narzędziami do analizy danych,
- zwiększanie znaczenia uczenia maszynowego,
- więcej metod weryfikujących poprawność wypełnienia.

3. Omówienie narzędzi i danych

3.1. Python

Python to interpretowany język wysokiego poziomu o ogólnym zastosowaniu. Stworzony został w roku 1991 przez Guido van Rossuma. Został zaprojektowany jako następca języka ABC [22], posiadający obsługę wyjątków i działający na systemie operacyjnym Amoeba. [23] Python jest wciąż wciąż rozwijany, najnowsza stabilna wersja to 3.11.2.

Python znany jest ze swojej prostej do zrozumienia składni, czytelnego kodu, wsparcia różnych paradygmatów programowania (obiektowego, imperatywnego, funkcyjnego), dużej biblioteki standardowej i bardzo szerokiego wyboru dodatkowych bibliotek. [24]

Do słabszych stron języka zaliczyć można słabą wydajność pod względem prędkości działania i wykorzystania pamięci bądź problemy z kompatybilnością kodu napisanego w różnych wersjach lub implementacjach Pythona. [24]

3.2. Visual Studio Code

Zintegrowane środowisko programistyczne, w skrócie IDE (od ang. integrated development enviroment) to aplikacja dostarczająca komplet narzędzi potrzebnych programistom w celu tworzenia aplikacji. Zazwyczaj IDE składa się z minimum: edytora kodu, kompilatora i debuggera. Niektóre środowiska oferują dodatkowe funkcje takie jak automatyczne uzupełnianie kodu, podświetlanie składni, automatyczne formatowanie kodu, narządzia do analizy kodu czy narządzia kontroli wersji. Dobór odpowiedniego środowiska programowania jest istotny, ponieważ może znacznie zwiększyć produktywność programisty. [25]

Jako środowisko programowania wykorzystane do przygotowania programu do testowania algorytmów wybrano Microsoft Visual Studio Code. [26] Jest to darmowy IDE o otwartym kodzie źródłowym. Stworzony został przez firmę Microsoft w roku 2015. Zaprojektowany został z myślą tworzenia aplikacji webowych i chmurowych z wykorzystaniem wielu języków. Ze względu na otwartość kodu, dostępne jest wiele rozszerzeń do programu, które znacznie ułatwiają tworzenie także projektów o dużym stopniu złożoności. [27]

3.3. GitHub

W celu umożliwienia pracy nad programem z wielu urządzeń oraz dla zachowania pełnej historii tworzenia programu wykorzystano integrację Visual Studio Code z repozytorium GitHub, tworząc prywatne repozytorium kodu. [28]

GitHub to platforma umożliwiająca programistom współpracę nad projektami, udostępnianie kodu i udzielanie się w projektach o otwartym kodzie źródłowym. Jest to największa tego typu platforma na świecie. [29]

Jednym z najważniejszych elementów GitHub jest Git. Jest to rozproszony system kontroli wersji, przygotowany przez Linusa Torvaldsa i wydany w roku 2005. Oryginalnie służył do pomocy przy rozwoju jądra Linux. Pozwala na śledzenie zmian w kodzie oraz pracę nad wieloma gałęziami projektu w tym samym czasie. [30]

3.4. Biblioteki

3.4.1. Pandas

Pandas to popularna biblioteka służąca manipulacji i analizy danych w Pythonie. Stworzona została w roku 2008 przez Wesa McKinney'a i jest stale rozwijana przez grupę deweloperów. Nazwa Pandas pochodzi od "Python data analysis". [2]

Najważniejsze zalety Pandas to:

- wsparcie dla wielu formatów danych, w tym CSV, Excel, SQL i inne,
- duża szybkość przeprowadzania operacji na danych,
- obsługa brakujących wartości w danych,
- łatwa integracja z innymi popularnymi bibliotekami,
- bardzo rozbudowana dokumentacja.

Pandas wykorzystuje dwie główne struktury danych: Series i DataFrame. Ta pierwsza to jednowymiarowa tablica wartości posiadająca indeksy każdego elementu, z kolei druga to dwuwymiarowa tablica wartości z indeksami zarówno rzędów jak i kolumn. Obydwie struktury mogą przechowywać dowolne typy danych. [31]

3.4.2. NumPy

NumPy to biblioteka dla Pythona wykorzystywana do pracy na obiektach będących wielowymiarowymi tablicami oraz udostęniajaca szereg narzędzi do obliczeń naukowych. Została stworzona w roku 2005 przez Travisa Oliphanta jako następca bibliotek Numeric [32] i Numarray [33]. Biblioteka jest wciąż rozwijana przez grupę programistów. NumPy jest szeroko wykorzystywana do przeprowadzania obliczeń naukowych ze względu na szereg zalet: [34][35]

- wspiera wielowymiarowe tabele, zarówno o homogenicznych jak i heterogenicznych typach danych,
- oferuje dużą ilość funkcji matematycznych, generatorów liczb pseudolosowych, transformat i innych narzędzi przydatnych w zastosowaniach naukowych,
- łatwo integruje się z innymi bibliotekami,
- posiada bardzo rozbudowaną dokumentację.

Do wad zaliczają się stosunkowo niska wydajność i problemy z obsługą niektórych typów danych i brakujących wartości. [35]

3.4.3. SciKit-learn

SciKit-learn to biblioteka zawierająca narzędzia związane z uczeniem maszynowym dla Pythona. Jest częścią większego zestawu narzędzi SciKit, zawierającego biblioteki oferujące szeroki wachlarz narzędzi do analizy danych. Początkowo stworzony przez Davida Cournapeau jako projekt w ramach "Google Summer of Code" w roku 2007, został później przepisany i rozwinięty przez Francuski Instytut Badań w Dziedzinie Informatyki i Automatyki (INRIA) i udostępniony publicznie w roku 2010.[36] SciKit-learn przestrzega zasad projektowania API dla oprogramowania uczenia maszynowego, które obejmują między innymi spójność, rozsądne domyślne ustawienia i dokumentację. [4]

3.4.4. EasyGUI

EasyGUI to biblioteka Pythona służaca do implementacji prostego interfejsu graficznego. Został stworzony przez Stephena Ferga i udostępniony w roku 2004. Oparty jest na bibliotece Tkinter [37]. Główną zaletą EasyGUI jest jego prosta składnia, pozwalajaca na tworzenie nieskomplikowanych aplikacji bez konieczności uczenia się stosowania bardziej zaawansowanych bibliotek. Osiągnięte to zostało przez zastosowanie

predefiniowanych okien spełniających najczęściej wykorzystywane role, takie jak okna wyboru, wyświetlanie wiadomości, wpisywanie tekstu i inne. Niestety zaprzestano dalszego rozwoju biblioteki, przez co nie można spodziewać się dodania nowych funkcji czy poprawy działania istniejących. [5]

3.5. Źródła danych

3.5.1. Użyte repozytoria danych

Aby wyniki badań niosły ze sobą odpowiednią wartość merytoryczną, potrzebne są odpowiednie zbiory danych na których zostaną przeprowadzone testy. W celu znalezienia odpowiednich zbiorów danych, przyjęto następujące założenia:

- zbiór danych musi być wystarczająco duży,
- zbiór danych musi zawierać odpowiedniż ilość atrybutów aby modele decyzyjne miały do dyspozycji wystarczającą ilość danych uczących,
- atrybuty powinny zawierać różnorodne typy danych w celu przetestowania wypełniania zarówno danych liczbowych (całkowitych i zmiennoprzecinkowych) jak i kategorycznych,
- zbiór danych nie może mieć pustych wartości.

Do wyszukania odpowiednich zbiorów danych wykorzystano narzędzie Google Dataset Search. [38][39] Z jego pomocą wybrano 2 zbiory danych z różnych dziedzin. Po uprzedniej ich obróbce zostały wykorzystane do przeprowadzenia testów algorytów wypełniania.

3.5.2. Adult Data Set

Piwerwszy zbiór danych "Adult Data Set"zawiera dane ze spisu ludności przeprowadzonego w roku 1994 w Stanach Zjednoczonych. Jest szeroko wykorzystywany do testowania uczenia maszynowego. Zawiera ponad 30000 rekordów i 15 atrybutów. [40] Opis atrybutów:

- age: wiek spisanej osoby, liczba całkowita,
- workclass: rodzaj zatrudnienia, dane kategoryczne, 8 możliwych wartości,

- fnlwgt: jaka proporcja populacji ma identyczny zestaw pozostałych wartości, liczba całkowita,
- education: osiągnięty poziom edukacji, dane kategoryczne, 16 możliwych wartości,
- education-num: osiągnięty poziom edukacji zakodowany jako liczba całkowita,
- martial-status: status matrymonialny, dane kategoryczne, 7 możliwych wartości,
- occupation: zawód, dane kategoryczne, 14 możliwych wartości,
- relationship: rola w związku, dane kategoryczne, 6 możliwych wartości,
- race: klasyfikacja rasowa, dane kategoryczne, 5 możliwych wartości,
- sex: płeć, dane kategoryczne, 2 możliwe wartości,
- capital-gain: zysk kapitału w zwiazku z inwestycjami, liczba całkowita,
- capital-gain: strata kapitału w zwiazku z inwestycjami, liczba całkowita,
- hours-per-week: ilość godzin pracujących w tygodniu, liczba całkowita,
- native-country: kraj pochodzenia, dane kategoryczne, 41 możliwych wartości,
- attribute: czy osoba zarabia powyżej czy poniżej 50000$ rocznie.

Ten zbiór danych został wybrany ze względu na występowanie zarówno atrybutów liczbowych jak i kategorycznych, zadowalajacą ilość rekordów oraz atrybutów. został wybrany do celu przetestowanie skuteczności działania algorytmów do wypełniania brakujących miejsc w zbiorach danych z brakami w danych o różnych typach. Nie wymaga dodatkowej obróbki przed rozpoczęciem testów.

3.5.3. Stock Exchange Data

Drugi zbiór danych "Stock Exchange Data"zawiera informacje o cenach akcji na giełdach w różnych krajach w latach 1965-2021. Dane zostały zebrane z Yahoo Finance, posiadającego dane o giełdzie z wielu lat w wielu krajach. Posiada ponad 100000 rekordów i 9 atrybutów. [41] Opis atrybutów:

- Index: symbol wskazujacy z jakiej giełdy pochodzą dane, dane kategoryczne, 5 możliwych wartości,

- Date: data obserwacji, dane kategoryczne,
- Open: cena akcji podczas otwarcia, liczba wymierna,
- High: najwyższa cena w ciągu dnia, liczba wymierna,
- Low: najniższa cena w ciągu dnia, liczba wymierna,
- Close: cena akcji w momencie zamknięcia, liczba wymierna,
- Adj Close: cena akcji w momencie zamknięcia skorygowana o podziały jak i dywidendy, liczba wymierna,
- Volume: liczba akcji będących przedmiotem obrotu w ciągu dnia sesyjnego, liczba całkowita,
- CloseUSD: cana akcji w momencie zamknięcia wyrażona w dolarach amerykańskich.

Ten zbiór danych został wybrany ze względu na bardzo popularną kategorię danych, to jest dane finansowe. Ma na celu przetestowanie skuteczności działania algorytmów w przypadku danych numerycznych, w szegółności liczb wymiernych (typu float). W celu lepszego przygotowania do testów zakodowano kolumnę Data z wykorzystaniem label encoding, to jest zamiany danych na postać numeryczną. Usunięto też rekordy posiadające wartość "0"w kolumnie "Volume". Ich duża liczba (ponad 30%) mogłaby negatywnie wpłynąć na uczenie modeli decyzyjnych. W wyniku tego zmniejszono liczbę rekordów do ponad 62000.

4. Implementacja i testy

4.1. Opis przygotowanego programu

4.1.1. Założenia i realizacja

Założono, że program ma realizować 3 zadania:

1) Przygotować dane do wypełniania poprzez sztuczne utworzenie brakujacych wartości.

2) Wypełnić brakujące wartości z wykorzystaniem wybranych algorytmów.

3) Ocenić skuteczność wypełniania w celu porównania algorytmów.

Poszczególne zadania zrealizowano jako osobne moduły.

Przyjęto też następujące założenia:

1) Wykorzystanym językiem ma być Python.

2) Program ma być napisany zgodnie z paradygmatem programowania obiektowego.

3) Poszczególne klasy mają być zawarte w osobnych plikach.

4) Interakcja z programem ma opierać się o prosty interfejs graficzny.

5) Dostęp do wszystkich modułów programu ma być zapewniony z jednego miejsca.

6) Pliki wygenerowane przez jeden moduł mają być przygotowane w sposób umożliwiający wykorzystanie ich przez kolejny. Oprócz odpowiedniego formatowania wewnątrz pliku, oznacza to przyjęcie konwencji nazewnictwa plików opartej o prefiksy i sufiksy.

Program składa się z następujacych plików:

- mgr_main.py: główny plik nie zawierający żadnej klasy, odpowiadający za wybór modułu do uruchomienia, i uruchomienie odpowiedniego modułu po wybraniu,

- mgr_nan_gen.py: plik zawierajacy klasę NanGen, odpowiadającą za realizację modułu przygotowujacego plik,

- mgr_fill.py: plik zawierający klasę Fill, odpowiadającą za realizację modułu wypełniajacego brakuące dane,

- mgr_data.py: plik zawierający klasę Data, odpowiadającą za wybranie pliku do wypełnienia i przygotowanie do do dalszej obróbki, oraz klasę PrepareData, odpowiadającą za przygotowanie danych do przekazania silnikowi uczenia maszynowego celem wypełnienia oraz późniejszemu przywróceniu danym ich pierwotnego wyglądu

- mgr_di.py: plik zawierjący klasę DownImpu, odpowiadającą za przygotowanie danych dla algorytmu trzeciego.

- mgr_temp_fill: plik zawierający klasę TempFill, odpowiadającą za tymczasowe wypełnianie brakujących miejsc, potrzebne podczas przygotowywania danych dla algorytmu Prostego

- mgr_acc: plik zawierający klasę AccuracyTester, odpowiadającą za obliczanie skuteczności wypełniania danych.

Wykorzystując narzędzie auto-py-to-exe, utworzono plik mgr_suite.exe, pozwalajacy uruchomić program bez konieczności instalowania interpretera Python i potrzebnych bibliotek. [42]

4.1.2. Działanie programu

Poniżej zaprezentowano działanie programu na przykładzie pliku data_stock.csv. Zostanie on najpierw przygotowany do testów, następnie brakujace dane zostaną wypełnione z wykorzystaniem jednego z algorytmów, po czym zostanie obliczona dokładność tego wypełnienia.

Po uruchomieniu mgr_suite.exe wyświetlone zostaje okno służące do wyboru modułu, pokazane na rysunku 4.1.

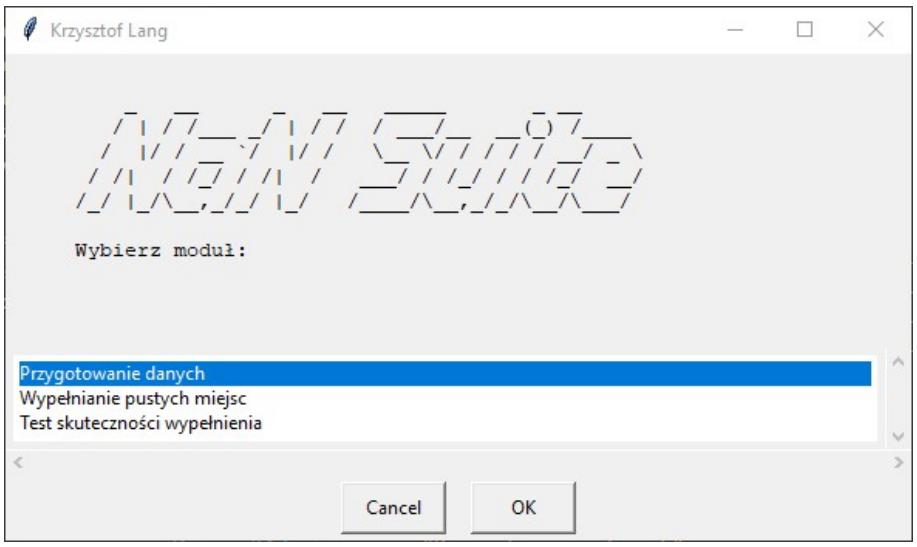

Rysunek 4.1: Główne okno programu, pozwalajace na wybór modułu do uruchomienia

Pierwszy moduł odpowiada za przygotowanie danych do wypełniania poprzez usunięcie losowych wartości ze zbioru danych. Pierwszym krokiem jest wybranie pliku który ma zostać przygotowany z użyciem okna pokazanego na rysunku 4.2. Lista plików generowana jest na podstawie plików znajdujących się w tym samym folderze co uruchamiany program spełniających założony format nazwy. Założono, że pliki które nadają się do wypełnienia mają być zapisane w formacie CSV, natomiast nazwa zaczynać się ma od prefiksu “data_” i nie posiadać żadnych sufiksów.

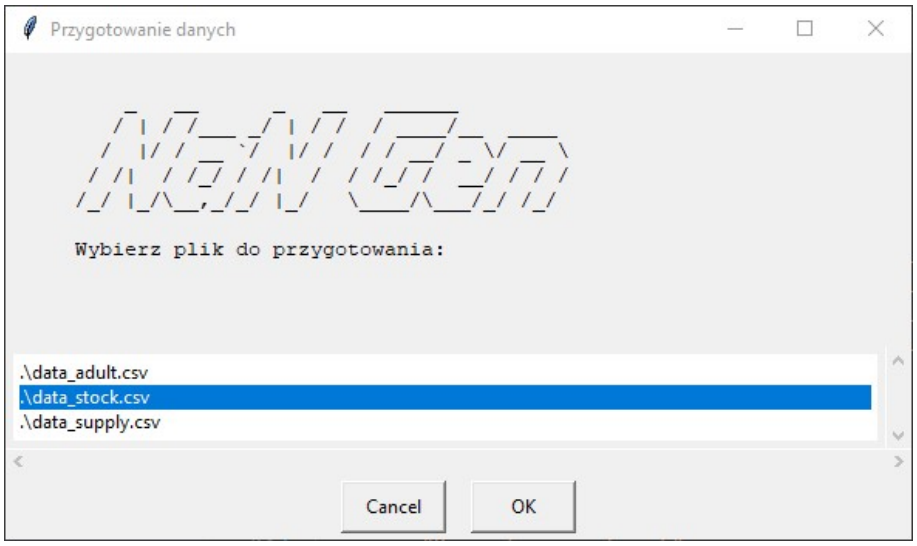

Rysunek 4.2: Okno wyboru pliku do przygotowania

Następnie wybrane z listy zostają kolumny w których maja zostać usunięte

dane. Wyboru dokonuje się z użyciem okna pokazanego na rysunku 4.3. Kolumny do wyboru wyekstrahowane są bezpośrednio z załadowanego wcześniej pliku. Wybrać można dowolną kombinację, lecz zalecane jest poniżej 50%.

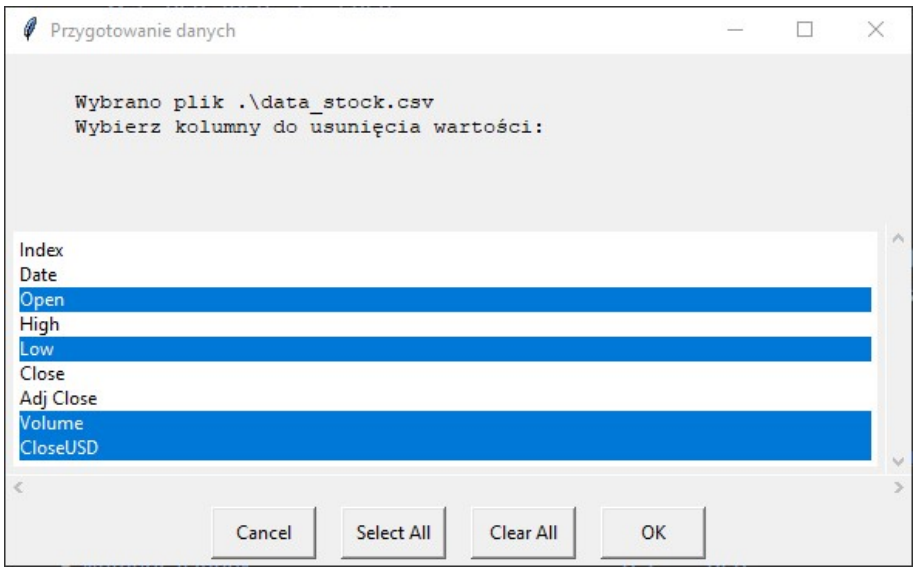

Rysunek 4.3: Okno wyboru kolumn

W wybranych kolumnach zostaje usunięte od 5% do 15% wartości - dla każdej kolumny faktyczna wartość jest losowana. Dodatkowo stworzony zostaje plik przechowujęcy informacje które wartości zostały usunięte. Ta informacja zostaje później wykorzystana do oceny skuteczności wypełnienia zbioru danych. Po zakończeniu usuwania wartości wyświetlone zostaje okno z podsumowaniem jak na rysunku 4.4. Nazwa utworzonego pliku z gotowymi danymi tworzona jest poprzez dodanie sufiksu "_holes_X" do nazwy oryginalnego pliku, gdzie X to kolejna liczba naturalna. Umożliwia to tworzenie plików z danymi usuniętymi z różnych zestawów kolumn bez konieczności ręcznej zmiany ich nazw. Nazwa pliku z informacją które dane zostały usunięte tworzona jest przez dodanie sufiksu "_journal" do nazwy oryginalnego pliku.

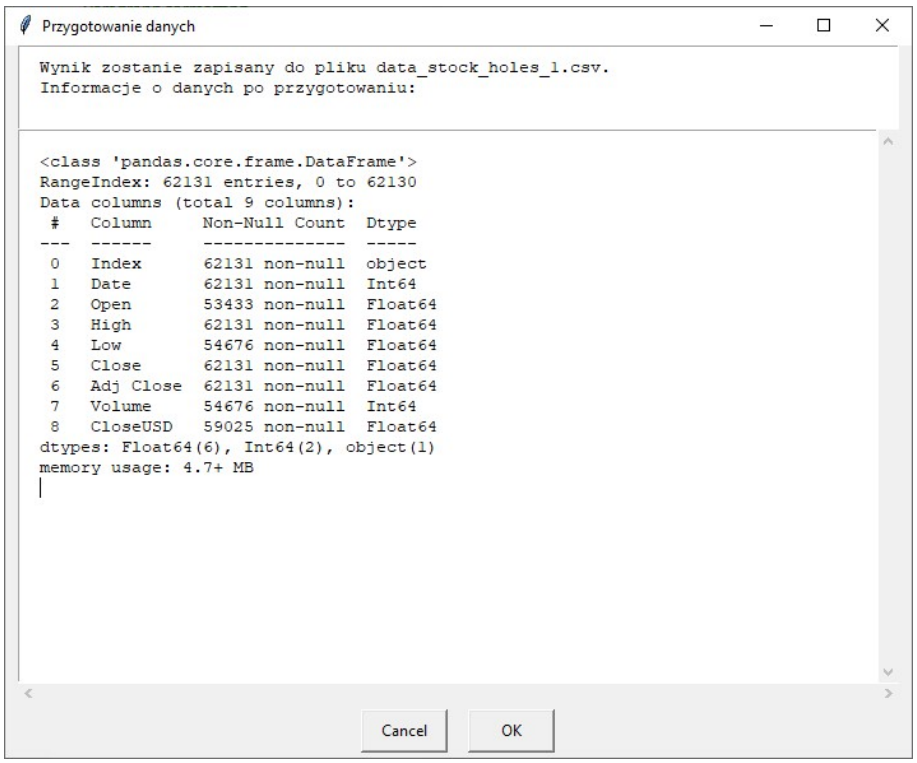

Rysunek 4.4: Okno z podsumowaniem

Drugi moduł służy do wypełniania brakujacych wartości w zbiorze danych z użyciem wybranego algorytmu.

Najpierw należy wskazać plik który ma zostać wypełniony z użyciem okna wyboru pokazanego na rysunku 4.5. Tak jak wcześniej, lista tworzona jest na podstawie plików w folderze i przyjętej konwencji nazewnictwa plików. Wyświetlane są wyłącznie pliki posiadające sufiks "_holes_X" w nazwie, bez kolejnych sufiksów.

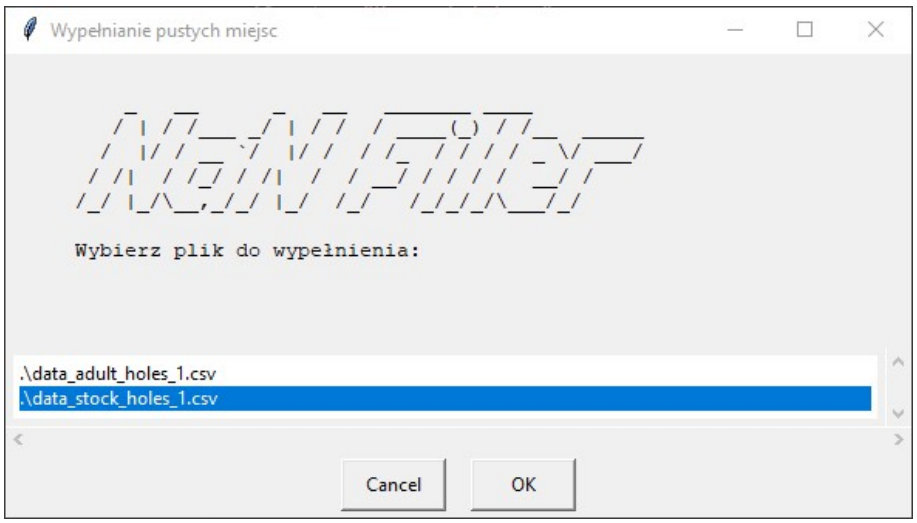

Rysunek 4.5: Okno wyboru pliku do wypełnienia

Następnie z użyciem okna jak na rysunku 4.6 wybrany zostaje algorytm który ma zostać wykorzystany do wypełniania brakujących wartości. Wyświetlona zostaje też nazwa wybranego wcześniej pliku w celu uniknięcia błędu wybrania niewłaściwego pliku.

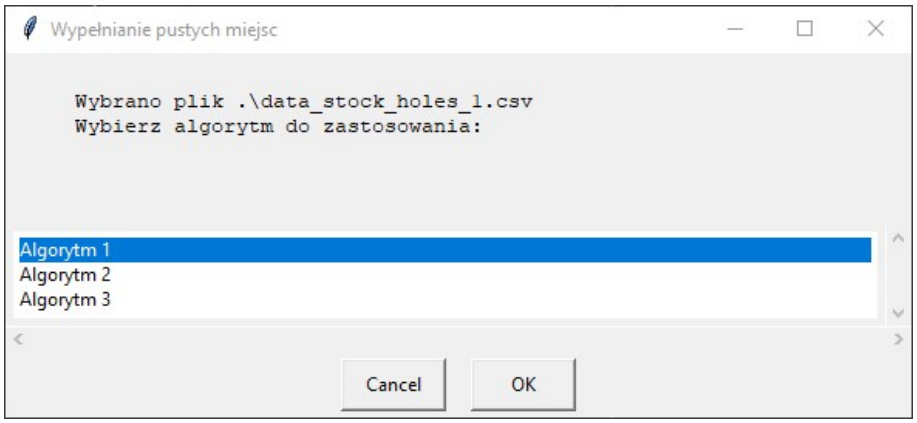

Rysunek 4.6: Okno wyboru algorytmu

Puste miejsca zostają wypełnione z wykorzystaniem wybranego algorytmu. Dokładny sposób działania algorytmów zostanie opisany w kolejnych rozdziałach. Po zakończeniu wypełniania wyświetlone zostaje podsumowanie jak na rysunku 4.7. Nazwa pliku wynikowego tworzona jest poprzez dodanie sufixu "_filled_Y", gdzie Y to nazwa wybranego algorytmu.

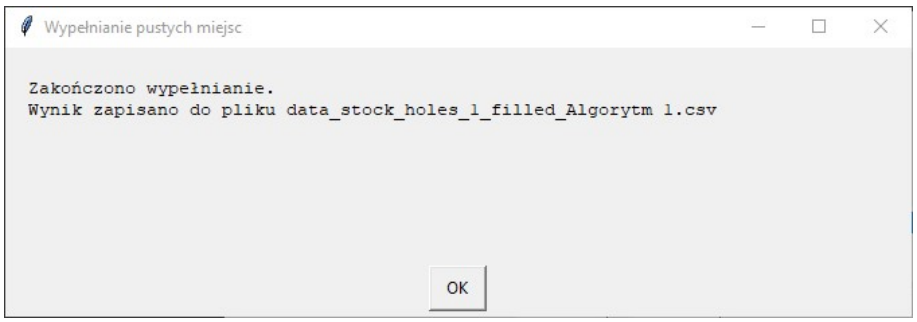

Rysunek 4.7: Okno z podsumowaniem wypełniania

Ostatni moduł odpowiada za wygenerowanie danych, które można wykorzystać do oceny skuteczności wypełniania brakujących wartości. Jako wystarczające uznano procent skuteczności wypełniania dla danych kategorycznych i liczb całkowitych oraz średnie odchylenie bezwzględne dla wszystkich danych liczbowych. Obie wartości są obliczane dla poszczególnych wypełnionych kolumn.

Jak w przypadku poprzednich modułów, zacząć należy od wyboru pliku który ma zostać poddany analizie. Wyboru dokonuje się z użyciem okna pokazanego na rysunku 4.8. Wyświetlane są tylko pliki zawierające słowo “filled” w nazwie, ponieważ takie pliki posiadają wartości wypełnione za pomocą któregoś algorytmu z użyciem odpowiedniego modułu.

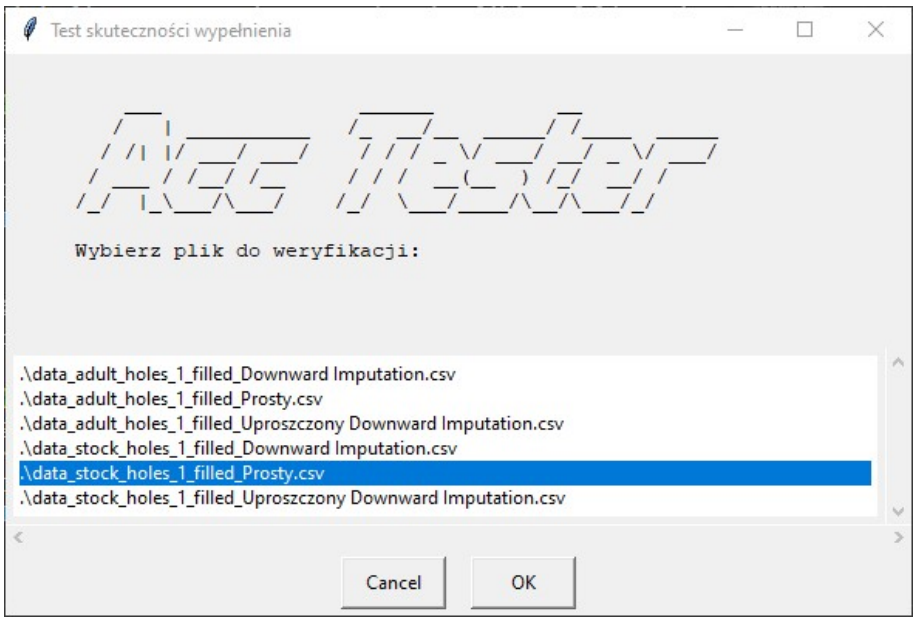

Rysunek 4.8: Okno wyboru pliku do analizy

Z użyciem wybranego pliku, oryginalnego pliku z danymi przed usunięciem losowych danych oraz pliku z informacją które dane zostały usunięte a następnie wypełnione, przeprowadzane jest obliczanie skuteczności wypełniania danych.

Obliczenie procentowej skuteczności wypełnienia przebiega następująco:

1) Sprawdzenie ilości wypełnianych wartości w danej kolumnie.

2) Zsumowanie ilości poprawnie wypełnionych danych w kolumnie poprzez porównanie wartości o współrzędnych zapisanych w pliku tworzonym podczas przygotowywania danych.

3) Zastosować wzór 4.1:

$$ACC = \frac{m}{n} \times 100\% \tag{4.1}$$

gdzie: ACC – procentowa skuteczność wypełnienia kolumny, m – ilość poprawnie wypełnionych wartości, n – ilość wypełnionych wartości.

Aby obliczyć średnie odchylenie bezwzględne należy zastosować wzór 4.2:

$$AAD = \frac{\sum_{i=1}^{n} |x_i - \hat{x_i}|}{n} \tag{4.2}$$

gdzie: AAD – średnie odchylenie bezwzględne dla danej kolumny, n – ilość wypełnionych wartości w kolumnie, x_i – wartość wypełnionego i-tego elementu kolumny, $\hat{x_i}$ – oryginalna wartość i-tego elementu kolumny.

Po zakończeniu obliczeń, wyświetlane jest podsumowanie jak na rysunku 4.9, a wynik obliczeń zapisywany jest w dwóch plikach

- wyniki obliczania procentowej skuteczności jest zapisywany w pliku o nazwie tworzonej przez dodanie do nazwy analizowanego pliku sufiksu "_aad",

- wyniki obliczania średniego odchylenia bezwzględnego jest zapisywany w pliku o nazwie tworzonej przez dodanie do nazwy analizowanego pliku sufiksu "_acc".

Rysunek 4.9: Okno z podsumowaniem

4.2. Opis implementacji algorytmów

Implementowane algorytmy opierają się o kolejne rozwinięcia idei zaprezentowanej w [43]. Polega ona na sformułowaniu problemu wypełniania problemu wypełniania brakujących wartości jako problemu decyzyjnego. Wynikają z tego następujące założenia:

- kolumny wypełniane są pojedyńczo,
- samo wypełnianie przeprowadzane jest przez system decyzyjny,
- algorytm ma za zadanie wybrać kolejność wypełniania kolumn oraz określić jakie kolumny będą zawarte w zbiorze danych uczących systemu decyzyjnego.

Działanie poszczególnych algorytmów zostanie zaprezentowane na przykładowej tabeli 4.1 przedstawiającej zbiór danych:

Tabela 4.1: Tabela wyjściowa

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	*	*	x	*	*	*	x	*	*	*	x	*	*	*
2	x	*	*	*	*	*	*	*	*	*	*	x	*	*
3	*	*	*	*	x	*	*	*	*	*	*	x	*	*
4	x	*	x	*	x	*	x	x	*	*	x	x	*	*
5	*	*	*	*	x	*	*	x	x	*	*	*	*	*
6	*	*	*	*	x	*	x	x	*	*	*	*	*	*
7	*	*	*	*	x	*	*	*	*	*	*	*	*	*
8	*	*	*	*	*	*	*	x	*	*	x	*	x	*
9	*	*	*	*	x	*	*	*	x	*	*	*	x	*
10	*	*	*	*	*	*	x	*	x	*	*	*	*	*
11	*	x	*	*	x	*	*	*	*	*	*	*	*	*

gdzie: $*$ – istniejąca wartość, x – brakująca wartość.

4.2.1. Algorytm pierwszy

Procedura dla algorytmu pierwszego wygląda następująco:

1) Tworzony jest zbiór kolumn z brakującymi wartościami X. Dla przykładowej tabeli zbiór będzie wyglądał następująco:

   $X = \{A, B, C, E, G, H, I, K, L, M\}$.

2) Kolumny w zbiorze X są następnie sortowane od kolumn zawierających najmniejszą ilość brakujących wartości do zawierających ich najwięcej, dając ciąg η. W przypadku kolumn o takiej samej ilości brakujących danych kolejność nie ma znaczenia. Dla przykładowej tabeli zbiór ten będzie wyglądał następująco:

   $\eta = (B, M, C, A, L, K, I, H, G, E)$.

3) Pierwszy element w ciągu η zostaje wybrany jako kolumna która zostanie wypełniona. W przykładzie będzie to element B.

4) Tabela zostaje rozdzielona na dwie: w jednej znajdują się rekordy w których w kolumnie wybranej do wypełnienia znajdują się dane, a w drugiej rekordy w

których w wybranej tabeli danych brakuje. Dla przykładowej tabeli będzie to wyglądało następująco, gdzie tabela 4.2 przedstawia tabelę z danymi w wybranej kolumnie, natomiast tabela 4.3 przedstawia tabelę z brakiem danych w wybranej kolumnie.

Tabela 4.2: Tabela wydzielona z oryginalnej, zawierająca wyłacznie rekordy z danymi w rozważanej kolumnie

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	*	*	x	*	*	*	x	*	*	*	x	*	*	*
2	x	*	*	*	*	*	*	*	*	*	*	x	*	*
3	*	*	*	*	x	*	*	*	*	*	*	x	*	*
4	x	*	x	*	x	*	x	x	*	*	x	x	*	*
5	*	*	*	*	x	*	*	x	x	*	*	*	*	*
6	*	*	*	*	x	*	x	x	*	*	*	*	*	*
7	*	*	*	*	x	*	*	*	*	*	*	*	*	*
8	*	*	*	*	*	*	*	x	*	*	x	*	x	*
9	*	*	*	*	x	*	*	*	x	*	*	*	x	*
10	*	*	*	*	*	*	x	*	x	*	*	*	*	*

Tabela 4.3: Tabela wydzielona z oryginalnej, zawierająca wyłacznie rekordy z brakiem danych w rozważanej kolumnie

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
11	*	x	*	*	x	*	*	*	*	*	*	*	*	*

5) Pierwsza z tabel - w przykładzie tabela 4.2 - posłuży do trenowania modelu uczenia maszynowego. Wypełniana kolumna służy jako cel, a pozostałe jako dane uczące.

6) Następnie nauczony model zostaje wykorzystany do wypełnienia brakujących wartości w drugiej tabeli, w przykładzie tabeli 4.3.

7) Na koniec tabele są łączone w jedną co w przykładzie poskutkuje tabelą 4.4, a algorytm jest powtarzany aż do wypełnienia wszystkich brakujących wartości.

Tabela 4.4: Tabela prezentująca wygląd danych po pojedynczym przejściu głównej pętli algorytmu

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	*	*	x	*	*	*	x	*	*	*	x	*	*	*
2	x	*	*	*	*	*	*	*	*	*	*	x	*	*
3	*	*	*	*	x	*	*	*	*	*	*	x	*	*
4	x	*	x	*	x	*	x	x	*	*	x	x	*	*
5	*	*	*	*	x	*	*	x	x	*	*	*	*	*
6	*	*	*	*	x	*	x	x	*	*	*	*	*	*
7	*	*	*	*	x	*	*	*	*	*	*	*	*	*
8	*	*	*	*	*	*	*	x	*	*	x	*	x	*
9	*	*	*	*	x	*	*	*	x	*	*	*	x	*
10	*	*	*	*	*	*	x	*	x	*	*	*	*	*
11	*	*	*	*	x	*	*	*	*	*	*	*	*	*

4.2.2. Algorytm drugi

Algorytm drugi jest rozwinięciem pierwszego. Różni się sposobem wyboru kolumn mających pełnić rolę danych uczących. Eliminuje on z tego zbioru kolumny które również posiadają brakujące dane. Oznacza to, że kolumny wypełniane w pierwszej kolejności wypełniane są z użyciem silnika uczenia maszynowego uczącego się na mniejszej ilości danych, lecz lepszej jakości.

Procedura dla algorytmu drugiego wygląda następująco:

1) Tworzony jest zbiór kolumn z brakującymi wartościami X. Dla przykładowej tabeli zbiór będzie wyglądał następująco:

   $X = \{A, B, C, E, G, H, I, K, L, M\}$.

2) Kolumny w zbiorze X są następnie sortowane od kolumn zawierających najmniejszą ilość brakujących wartości do zawierających ich najwięcej, dając ciąg η. W przypadku kolumn o takiej samej ilości brakujących danych kolejność nie ma znaczenia. Dla przykładowej tabeli zbiór ten będzie wyglądał następująco:

   $\eta = (B, M, C, A, L, K, I, H, G, E)$.

3) Pierwszy element w ciągu η zostaje wybrany jako kolumna która zostanie wypełniona. W przykładzie będzie to element B.

4) Tabela zostaje podzielona na dwie. W jednej znajdują się kolumny z pustymi wartościami, oprócz tej która ma zostać wypełniona. W drugiej znajdują się kolumny pełne oraz ta wyznaczona do wypełnienia. Tabele 4.5 i 4.6 przedstawiają rodzielenie tabeli dla rozważanego przykładu:

Tabela 4.5: Tabela wydzielona z oryginalnej, zawierająca tylko kolumny z brakującymi danymi, z wyjątkiem wyznaczonej do wypełnienia

	A	C	E	G	H	I	K	L	M
1	*	x	*	x	*	*	x	*	*
2	x	*	*	*	*	*	*	x	*
3	*	*	x	*	*	*	*	x	*
4	x	x	x	x	x	*	x	x	*
5	*	*	x	*	x	x	*	*	*
6	*	*	x	x	x	*	*	*	*
7	*	*	x	*	*	*	*	*	*
8	*	*	*	*	x	*	x	*	x
9	*	*	x	*	*	x	*	*	x
10	*	*	*	x	*	x	*	*	*
11	*	*	x	*	*	*	*	*	*

Tabela 4.6: Tabela wydzielona z oryginalnej, zawierająca tylko kolumny bez brakujących danych i kolumnę wyznaczoną do wypełnienia

	B	D	F	J	N
1	*	*	*	*	*
2	*	*	*	*	*
3	*	*	*	*	*
4	*	*	*	*	*
5	*	*	*	*	*
6	*	*	*	*	*
7	*	*	*	*	*
8	*	*	*	*	*
9	*	*	*	*	*
10	*	*	*	*	*
11	x	*	*	*	*

5) Tabela z kolumną do wypełnienia znowu zostaje rozdzielona. W jednej znajdują się rekordy w których w kolumnie wybranej do wypełnienia znajdują się dane, a w drugiej rekordy w których w wybranej tabeli danych brakuje. Dla przykładowej tabeli będzie to wyglądało następująco, gdzie tabela 4.7 przedstawia tabelę z danymi w wybranej kolumnie, natomiast tabela 4.8 przedstawia tabelę z brakiem danych w wybranej kolumnie.

Tabela 4.7: Tabela wydzielona z oryginalnej, zawierająca tylko kolumny bez brakujących danych i kolumnę wyznaczoną do wypełnienia

	B	D	F	J	N
1	*	*	*	*	*
2	*	*	*	*	*
3	*	*	*	*	*
4	*	*	*	*	*
5	*	*	*	*	*
6	*	*	*	*	*
7	*	*	*	*	*
8	*	*	*	*	*
9	*	*	*	*	*
10	*	*	*	*	*

Tabela 4.8: Tabela wydzielona z oryginalnej, zawierająca tylko kolumny bez brakujących danych i kolumnę wyznaczoną do wypełnienia

	B	D	F	J	N
11	x	*	*	*	*

6) Pierwsza z tabel - w przykładzie tabela 4.7 - posłuży do trenowania modelu uczenia maszynowego. Wypełniana kolumna służy jako cel, a pozostałe jako dane uczące.

7) Następnie nauczony model zostaje wykorzystany do wypełnienia brakujących wartości w drugiej tabeli, w przykładzie tabeli 4.8.

8) Następnie tabele są łączone spowrotem w jedną, przywracając oryginalne rozmiary. W pierwszej kolejności łączone są ze sobą tabele które brały udział w uczeniu i wypełnianiu. W przykładzie będą to tabele 4.7 i 4.8 tworząc 4.9.

Tabela 4.9: Tabela wynikająca z połączenia tabel biorących udział w nauczaniu i wypełnianiu

	B	D	F	J	N
1	*	*	*	*	*
2	*	*	*	*	*
3	*	*	*	*	*
4	*	*	*	*	*
5	*	*	*	*	*
6	*	*	*	*	*
7	*	*	*	*	*
8	*	*	*	*	*
9	*	*	*	*	*
10	*	*	*	*	*
11	*	*	*	*	*

9) Na koniec dołączana jest wcześniej utworzona tabela zawierająca wyłącznie kolumny z brakującymi wartościami. W przykładzie oznacza to łączenie tabel 4.9 i 4.5, uzyskując tabelę 4.10.

Tabela 4.10: Tabela prezentująca wygląd danych po pojedynczym przejściu głównej pętli algorytmu

	B	D	F	J	N	A	C	E	G	H	I	K	L	M
1	*	*	*	*	*	*	x	*	x	*	*	x	*	*
2	*	*	*	*	*	x	*	*	*	*	*	*	x	*
3	*	*	*	*	*	*	*	x	*	*	*	*	x	*
4	*	*	*	*	*	x	x	x	x	x	*	x	x	*
5	*	*	*	*	*	*	*	x	*	x	x	*	*	*
6	*	*	*	*	*	*	*	x	x	x	*	*	*	*
7	*	*	*	*	*	*	*	x	*	*	*	*	*	*
8	*	*	*	*	*	*	*	*	*	x	*	x	*	x
9	*	*	*	*	*	*	*	x	*	*	x	*	*	x
10	*	*	*	*	*	*	*	*	x	*	x	*	*	*
11	*	*	*	*	*	*	*	x	*	*	*	*	*	*

4.2.3. Algorytm trzeci

Algorytm trzeci jest kolejnym rozwinięciem drugiego. On również skupia się głównie na zmianie logiki stojącej za doborem kolumn do wykorzystania w uczeniu silnika. Dodatkowo zmieniany jest sposób wyboru kolejności w jakiej wypełniane są kolumny. W przeciwieństwie do poprzedniego algorytmu, kolejność wypełniania kolumn nie jest dyktowana przez samą ilość brakujących wartości, a ilość brakujących wartości występujących w tych samych rekordach. Ma to na celu jak najbardziej efektywne uzyskanie informacji mających znaczenie przy wypełnianiu kolejnych kolumn. Również w tym celu kolumny o najmniejszym wpływie dla wypełniania innych kolumn wypełniane są w sposób prosty, to znaczy w oparciu o najczęściej występującą wartość lub średnią wartość w kolumnie, zależnie od typu danych.

Procedura dla algorytmu trzeciego wygląda następująco:

1) Tworzony jest zbiór kolumn z brakującymi wartościami X. Dla przykładowej tabeli zbiór będzie wyglądał następująco:

   $X = \{A, B, C, E, G, H, I, K, L, M\}$

2) Ze zbioru X wybierana jest kolumna z największą liczbą brakujących wartości.

Ta kolumna kolumna jest usuwana ze zbioru X i dodawana do ciągu η, natomiast liczba brakujących wartości w tej kolumnie dodawana jest do ciągu δ. W przykładzie jest to kolumna E z 7 brakującymi elementami, a zbiór i ciągi będą wyglądały następująco:

$X = \{A, B, C, G, H, I, K, L, M\}$, $\eta = (E)$, $\delta = (7)$

3) Następnie z tak powstałego zbioru X zostaje wybrana kolumna mająca najwięcej wspólnych z poprzednio wybraną kolumną brakujacych wartości w rekordach. W przypadku gdy liczba wspólnych braków jest równa dla kilku kolumn, można wybrać dowolną z nich. Wybrana kolumna usuwana jest ze zbioru X i dodawana do ciągu η, a liczba wspólnych brakujących wartości do ciągu δ. W przykładzie jest to H, z 3 wspólnymi elementami. Poskutkuje to zbiorem i ciągami:

$X = \{A, C, G, I, K, L, M\}$, $\eta = (E, H)$, $\delta = (7, 3)$

4) Powyższy krok jest powtarzany aż do wyczerpania elementów zbioru X W ten sposób tworzone są 2 ciągi. Jeden zawiera kolumny w uzyskanej w ten sposób kolejności, oznaczony jako η, oraz drugi mu odpowiadający oznaczony δ, zawierający wartości liczbowe oznaczające liczbę wspólnych z poprzednim elementem brakujacych wartości. Te ciągi dla przykładowej tabeli będą wyglądać następująco:

$\eta = (E, H, G, K, C, L, A, I, M, B)$, $\delta = (7, 3, 2, 2, 2, 1, 2, 0, 1, 0)$

5) Jeśli ciąg δ zawiera na końcu wartości zerowe to są one usuwane z tego ciągu, a odpowiadające im kolumny zostają wypełnione w sposób prosty i usuwane z ciągu η. W przykładzie poskutkuje to ciągami:

$\eta = (E, H, G, K, C, L, A, I, M)$, $\delta = (7, 3, 2, 2, 2, 1, 2, 0, 1)$

6) Tabela zostaje rozdzielona na podstawie zawartości ciągu η. Jedna tabela wynikowa zawiera kolumny zawarte w tym ciągu, a druga pozostałe, zawierająca wyłącznie kompletne dane. Tabele dla przykładu będą wyglądać następująco, gdzie tabela 4.11 zawiera kolumny z ciągu η, a tabela 4.12 pozostałe:

Tabela 4.11: Tabela zawierająca kolumny zawarte w ciągu η

	A	C	E	G	H	I	K	L	M
1	*	x	*	x	*	*	x	*	*
2	x	*	*	*	*	*	*	x	*
3	*	*	x	*	*	*	*	x	*
4	x	x	x	x	x	*	x	x	*
5	*	*	x	*	x	x	*	*	*
6	*	*	x	x	x	*	*	*	*
7	*	*	x	*	*	*	*	*	*
8	*	*	*	*	x	*	x	*	x
9	*	*	x	*	*	x	*	*	x
10	*	*	*	x	*	x	*	*	*
11	*	*	x	*	*	*	*	*	*

Tabela 4.12: Tabela zawierająca kolumny nie zawarte w ciągu η

	B	D	F	J	N
1	*	*	*	*	*
2	*	*	*	*	*
3	*	*	*	*	*
4	*	*	*	*	*
5	*	*	*	*	*
6	*	*	*	*	*
7	*	*	*	*	*
8	*	*	*	*	*
9	*	*	*	*	*
10	*	*	*	*	*
11	*	*	*	*	*

7) Ze zbioru η usuwana jest kolumna będąca ostatnim elementem ciągu i dokładana do tabeli zawierającej kompletne dane. Ta kolumna zostanie wypełniana. Tabela dzielona jest na dwie, jedną zawierającą rekordy w których wypełniana kolumna zawiera dane, i drugą w której wypełniana kolumna danych nie posiada. Pierwsza z nich posłuży jako dane treningowe dla modelu uczenia maszynowego, a druga zostanie z jego użyciem wypełniona. W rozpatrywanym przypadku przenoszoną kolumną będzie M, więc ciągi po jej usunięciu będą wyglądały następująco:

$\eta = (E, H, G, K, C, L, A, I)$, $\delta = (7, 3, 2, 2, 2, 1, 2, 0)$ Z kolei tabela zawierająca dane treningowe będzie wyglądała jak 4.13 , natomist tabela do wypełnienia jak 4.14.

Tabela 4.13: Tabela zawierająca kolumny nie zawarte w ciągu η

	B	D	F	J	N	M
1	*	*	*	*	*	*
2	*	*	*	*	*	*
3	*	*	*	*	*	*
4	*	*	*	*	*	*
5	*	*	*	*	*	*
6	*	*	*	*	*	*
7	*	*	*	*	*	*
10	*	*	*	*	*	*
11	*	*	*	*	*	*

Tabela 4.14: Tabela zawierająca kolumny nie zawarte w ciągu η

	B	D	F	J	N	M
8	*	*	*	*	*	x
9	*	*	*	*	*	x

8) Następnie usyskane po wypełnieniu tabele są łączone w jedną, a powyższa procedura polegająca na przenoszeniu i wypełnianiu ostatniej kolumny z ciągu η jest powtarzana aż do jego wyczerpania i tym samym wypełnienia wszystkich

kolumn. Tabela 4.15 przedstawia tabelę po połączeniu tabel 4.13 i 4.14, gotową do dodania kolejnej tabeli z ciągu η

Tabela 4.15: Tabela gotowa do powtórzenia procedury dodania i wypełnienia kolumny

	B	D	F	J	N	M
1	*	*	*	*	*	*
2	*	*	*	*	*	*
3	*	*	*	*	*	*
4	*	*	*	*	*	*
5	*	*	*	*	*	*
6	*	*	*	*	*	*
7	*	*	*	*	*	*
8	*	*	*	*	*	*
9	*	*	*	*	*	*
10	*	*	*	*	*	*
11	*	*	*	*	*	*

4.3. Napotkane problemy

4.4. Testy algorytmów na wybranych źródłach danych

4.4.1. Procedura przeprowadzania testu

Procedura przeprowadzonych testów wyglądała następująco:

1) Wybrano zbiory danych do testów: Adult Data Set [40] i Stock Exchange Data [41].

2) Przygotowano dane w sposób umożliwiający wykorzystanie ich w programie. Dane zapisano do plików odpowiednio data_adult.csv i data_stock.csv.

3) Obydwa pliki załadowano do pierwszego modułu programu, przygotowującego dane poprzez wygenerowanie brakujacych wartości. Dla pliku data_adult.csv wybrano kolumny:

   - age – dane liczbowe typu int

- education – dane kategoryczne
- occupation – dane kategoryczne
- race – dane kategoryczne
- hours-per-week – dane liczbowe typu int
- attribute – dane kategoryczne

Te kolumny zostały wybrane aby przetestować skuteczność wypełniania zarówno danych liczbowych typu int jak i danych kategorycznych.

Dla pliku data_stock.csv wybrano z kolei kolumny:

- Open – dane liczbowe typu float
- Low – dane liczbowe typu float
- Volume – dane liczbowe typu int
- CloseUSD – dane liczbowe typu float

Te kolumny zostały wybrane aby przetestować skuteczność wypełniania zarówno danych liczbowych typu float oraz int.

W ten sposób wygenerowano gotowe do wypełniania pliki:

- data_adult_holes_1.csv
- data_stock_holes_1.csv

Oraz odpowiadające im pliki przechowujące informacje które dane usunięto:

- data_adult_holes_1_journal.csv
- data_stock_holes_1_journal.csv

4) Następnie dane zostały wypełnione z wykorzystaniem drugiego modułu programu. Do wypełniania obu plików wykorzystano wszystkie 3 algorytmy. Uzyskano w ten sposób zestawy wypełnionych plików:

Wypełnione pliki bazujące na Adult Data Set:

- data_adult_holes_1_filled_Algorytm 1.csv
- data_adult_holes_1_filled_Algorytm 2.csv

- data_adult_holes_1_filled_Algorytm 3.csv

Wypełnione pliki bazujące na Stock Exchange Data:

- data_stock_holes_1_filled_Algorytm 1.csv
- data_stock_holes_1_filled_Algorytm 2.csv
- data_stock_holes_1_filled_Algorytm 3.csv

5) Każdy z wypełnionych plików został następnie poddany analizie trzecim modułem programu. Wygenerował on dla każdego analizowanego pliku informacje o dokładności wypełniania. To te pliki są podstawą oceny skuteczności poszczególnych algorytmów. Wygenerowane pliki to:

- data_adult_holes_1_filled_Algorytm 1_aad.csv
- data_adult_holes_1_filled_Algorytm 1_acc.csv
- data_adult_holes_1_filled_Algorytm 2_aad.csv
- data_adult_holes_1_filled_Algorytm 2_acc.csv
- data_adult_holes_1_filled_Algorytm 3_aad.csv
- data_adult_holes_1_filled_Algorytm 3_acc.csv
- data_stock_holes_1_filled_Algorytm 1_aad.csv
- data_stock_holes_1_filled_Algorytm 1_acc.csv
- data_stock_holes_1_filled_Algorytm 2_aad.csv
- data_stock_holes_1_filled_Algorytm 2_acc.csv
- data_stock_holes_1_filled_Algorytm 3_aad.csv
- data_stock_holes_1_filled_Algorytm 3_acc.csv

4.4.2. Przedstawienie otrzymanych wyników

Wyniki testów zebrano i na ich przygotowano tabele 4.16, 4.17, 4.18 i 4.19 w czytelniejszy sposób przedstawiające wyniki testów, zaokrąglone do 3 miejsc po przecinku:

Tabela 4.16: Tabela porównująca średnie odchylenie wartości po wypełnianiu danych w zbiorze Adult Data Set

Kolumna	**Algorytm 1**	**Algorytm 2**	**Algorytm 3**
age	8,049	8,056	8,072
hours-per-week	7,290	7,324	7,324

Tabela 4.17: Tabela porównująca procentową skuteczność algorytmów w wypełnianiu danych w zbiorze Adult Data Set

Kolumna	**Algorytm 1**	**Algorytm 2**	**Algorytm 3**
age	3,673	3,647	3,520
education	100,000	100,000	100,000
occupation	26,724	24,005	26,658
race	80,434	18,481	16,822
hours-per-week	5,495	4,974	5,258
attribute	77,089	76,989	76,194

Tabela 4.18: Tabela porównująca średnie odchylenie wartości po wypełnianiu danych w zbiorze Stock Exchange Data

Kolumna	**Algorytm 1**	**Algorytm 2**	**Algorytm 3**
Open	38,639	38,487	38,652
Low	25,429	25,381	25,382
Volume	514744105,743	517121563,891	512315098,820
CloseUSD	1010,382	1036,041	1036,041

Tabela 4.19: Tabela porównująca procentową skuteczność algorytmów w wypełnianiu danych w zbiorze Stock Exchange Data

Kolumna	**Algorytm 1**	**Algorytm 2**	**Algorytm 3**
Open	0	0	0
Low	0	0	0
Volume	0	0	0
CloseUSD	0	0	0

4.4.3. Interpretacja wyników

Najważniejszym wnioskiem jest fakt, że różnice w skuteczności między poszczególnymi algorytmami są znikome. Nie jest to spowodowane charakterystyką danego zbioru danych ani ich typu - we wszystkich przypadkach różnice w procentowej skuteczności wypełniania nie przekraczają jednego punktu procentowego, a średnie odchylenienie nie różni się między algorytmami o więcej niż kilka procent.

Jedynym wyjątkiem jest tutaj kolumna “race”, której skuteczność dla algorytmu pierwszego po zaokrągleniu wypełniania wyniosła 80%, a dla drugiego i trzeciego odpowiednio 18% i 17%. Wynika to z faktu, że w algorytmie drugim i trzecim kolumny wypełniane jako pierwsze bazują na uczeniu z wykorzystaniem najmniejszej liczby danych. Jeśli w uczeniu silnika maszynowego mającego wypełnić tą kolumnę brakowało danych z którymi ta jest mocno skorelowana, słaba skuteczność wypełnienia jest spodziewana.

Kolejną zaobserwowaną właściwością jest duża rozpiętość uzyskanej dokładności wypełniania danych kategorycznych. Dla kolumny “education” jest to aż 100%,

dla “attribute” akceptowalne 77%, a dla “occupation” już tylko okolice 25%, niezależnie od wykorzystnego algorytmu (przypadek kolumny “race” zostaje tutaj pominięty, ponieważ został już omówiony wcześniej).

Tutaj rolę odgrywa stopień korelacji danych w jednej kolumnie z pozostałymi. Łatwo pokazać to na przykładzie kolumny “education”. Ponieważ kolumna “education-num” przechowuje dokładnie te same informacje lecz zakodowane w inny sposób (numerycznie zamiast tekstowo) odgadnięcie właściwej wartości przez uczenie maszynowe nie stanowi problemu. Dla pozostałych kolumn silnik nie znalazł porównywalnie mocnych korelacji, więc skuteczność wypełniania jest niższa.

Ogromne średnie odchylenie dla kolumny “Volume” prawdopodobnie wynika z błędu albo w przygotowanym programie albo wykorzystanym silniku uczenia maszynowego. Po sprawdzeniu uzupełnionych danych, okazało się że wszystkie one są ujemne, mimo że w oryginalnym zbiorze nie ma żadnych ujemnych wartości - ta kolumna przedstawia liczbę przeprowadzonych transakcji w ciągu dnia, wartości ujemne są więc niedopuszczalne.

Niska procentowa dokładność wypełniania danych liczbowych jest spodziewanym rezultatem. Ponieważ tylko idealne dopasowanie jest liczone jako poprawnie wypełniona wartość, nawet najmniejsze odstępstwa powodują spadek tego wskaźnika. Jest to szczególnie widoczne w przypadku danych typu float, gdzie ten wskaźnik wynosi 0%. Dla danych liczbowych znacznie ważniejszym wskaźnikiem jest średnie odchylenie wartości.

Powyższe sugeruje, że przyjęte założenie mówiące, że zmiana logiki stojącej za doborem kolejności wypełniania kolumn jest niepoprawne i w rzeczywistości ma stosunkowo niskie znaczenie. Ważny z kolei jest dobór kolumn wykorzystanych do trenowania silnika uczenia maszynowego, ponieważ może mieć to ogromny wpływ na dokładność, co dosadnie pokazała kolumna “race”.

5. Podsumowanie i wnioski końcowe

Temat niniejszej pracy dyplomowej magisterskiej brzmi “Implementacja wybranych algorytmów wypełniania brakujących wartości, dla strumieni dużych zbiorów danych”. Miała ona na celu przedstawić idee stojące za wypełnianiem brakujacych danych, zaprezentować działanie zaimplementowanych algorytmów oraz je porównać. Do implementacji wykorzystano program napisany w języku Python z zaimplementowanymi bibliotekami służącymi do obróbki i analizy danych. Testy przeprowadzono na wybranych odpowiednio dużych zbiorach danych.

Wnioski wyciągnięte z przeprowadzonych testów zaprzeczyły przyjętemu założeniu z myślą o którym przygotowywano algorytmy do testowania, czyli dużej roli kolejności w jakiej wypełniane są dane. Zwróciły one jednak uwagę na rolę wykorzystania jak największej ilości danych do trenowania silnika uczenia maszynowego.

Wypełnianie brakujących elementów w dużych zbiorach danych to wciąż rozwijająca się gałęź analizy danych. Rosnące znaczenie analizy danych dla kolejnych gałęzi przemysłu i nauki wymaga aby dane były tak dobrej jakości jak to możliwe, a to oznacza również ich kompletność. Różne dane wymagają różnych sposobów ich wypełniania. Podczas gdy dla niektórych może być wystarczające proste wstawienie średniej, inne dane będą wymagały zaawansowanych algorytmów ze zintegrowanymi elementami uczenia maszynowego i automatycznej korekcji błędów.

Autor za własny wkład pracy uważa:

- zebranie informacji dotyczących omawianego tematu,
- przygotowanie programu służącego do przeprowadzenia testów,
- przygotowanie algorytmów wypełniania brakujących wartości do porównania,
- przeprowadzenie testów, analiza uzyskanych wyników i wyciągnięcie wniosków.

Załączniki

Do pracy załączono kod źródłowy przygotowanej aplikacji.

Literatura

[1] https://www.python.org/. Dostęp 30.03.2023.

[2] https://pandas.pydata.org/. Dostęp 30.03.2023.

[3] https://numpy.org/. Dostęp 30.03.2023.

[4] https://scikit-learn.org/stable/. Dostęp 30.03.2023.

[5] https://easygui.sourceforge.net/. Dostęp 30.03.2023.

[6] https://archive-beta.ics.uci.edu/. Dostęp 30.03.2023.

[7] https://www.kaggle.com/datasets. Dostęp 30.03.2023.

[8] Sun Y., Shi Y., Zhang Z.: Finance Big Data: Management, Analysis, and Applications. International Journal of Electronic Commerce, 2019.

[9] Austin P., White I., Lee D., van Buuren S.: Missing Data in Clinical Research: A Tutorial on Multiple Imputation. The Canadian journal of cardiology vol. 37,9, 2020.

[10] Balk D., Leyk S., Jones B., Montgomery M.R., Clark A.: Understanding urbanization: A study of census and satellite-derived urban classes in the United States, 1990-2010. PLOS ONE, 2018.

[11] Casas P., D'Alconzo A., Zseby T., Mellia M.: Big-DAMA: Big Data Analytics for Network Traffic Monitoring and Analysis. 2016.

[12] https://www.scribbr.com/statistics/missing-data/. Dostęp 30.03.2023.

[13] Fisher R. A.: The Goodness of Fit of Regression Formulae, and the Distribution of Regression Coefficients. Journal of the Royal Statistical Society, 1922.

[14] Wilson E. B.: Probable Inference, the Law of Succession, and Statistical Inference. Journal of the American Statistical Association, 1927.

[15] Rubin D. B.: Multiple Imputation for Nonresponse in Surveys. Wileys, John Wiley & Sons, Indianapolis 198z.

[16] Bayzid S., Bhattacharjee A.: Machine learning based imputation techniques for estimating phylogenetic trees from incomplete distance matrices. BMC Genomics, 2019.

[17] https://towardsdatascience.com/implementation-and-limitations-of-imputation-methods-b6576bf31a6c. Dostęp 30.03.2023.

[18] https://www.oracle.com/pl/big-data/what-is-big-data/. Dostęp 30.03.2023.

[19] https://www.oecd.org/gov/digital-government/open-government-data.htm. Dostęp 30.03.2023.

[20] https://dane.gov.pl/pl. Dostęp 30.03.2023.

[21] Adnan F., Jamaludin K., Muhamad W., Miskon S.: A Review of Current Publications Trend on Missing Data Imputation Over Three Decades: Direction and Future Research. 2021.

[22] Geurts L., Meertens L., Pemberton S.: ABC Programmer's Handbook. Bosko Books, Londyn 2005.

[23] https://www.artima.com/articles/the-making-of-python. Dostęp 30.03.2023.

[24] Lutz M.: Learning Python, 5th Edition. O'Reilly Media Inc, Sebastopol 2013.

[25] https://www.redhat.com/en/topics/middleware/what-is-ide. Dostęp 30.03.2023.

[26] https://code.visualstudio.com/. Dostęp 30.03.2023.

[27] Johnson B.: Visual Studio Code: End-to-End Editing and Debugging Tools for Web Developers. John Wiley & Sons, Indianapolis 2019.

[28] https://github.com/. Dostęp 30.03.2023.

[29] Chacon S., Straub B.: Pro Git 2nd ed. Apress, 2014.

[30] Laster B.: Professional Git. John Wiley & Sons, Indianapolis 2017.

[31] Petrou T.: Pandas Cookbook: Recipes for Scientific Computing, Time Series Analysis and Data Visualization using Python. Packt Publishing, Birmingham 2017.

[32] https://pypi.org/project/Numeric/. Dostęp 30.03.2023.

[33] https://pypi.org/project/numarray/. Dostęp 30.03.2023.

[34] Ranjani J., Sheela A., Meena K. P.: "Combination of NumPy, SciPy and Matplotlib/Pylab -a good alternative methodology to MATLAB - A Comparative analysis"2019 1st International Conference on Innovations in Information and Communication Technology (ICIICT), Chennai 2019

[35] McKinney W.: Python for Data Analysis. O'Reilly Media Inc, Sebastopol 2012.

[36] https://www.inria.fr/en. Dostęp 30.03.2023.

[37] https://docs.python.org/3/library/tkinter.html. Dostęp 30.03.2023.

[38] https://datasetsearch.research.google.com/. Dostęp 30.03.2023.

[39] Noy N., Burgess M., Brickley D.: Google Dataset Search: Building a search engine for datasets in an open Web ecosystem. WebConf'2019, San Francisco 2019

[40] https://archive-beta.ics.uci.edu/dataset/2/adult. Dostęp 30.03.2023.

[41] www.kaggle.com/datasets/mattiuzc/stock-exchange-data. Dostęp 30.03.2023.

[42] https://pypi.org/project/auto-py-to-exe/. Dostęp 30.03.2023.

[43] Brański A.: Wybrane zagadnienia informatyki stosowanej. Oficyna Wydawnicza Politechniki Rzeszowskiej, Rzeszów 2020.

POLITECHNIKA RZESZOWSKA im. I. Łukasiewicza Rzeszów, 2023
Wydział Elektrotechniki i Informatyki

STRESZCZENIE PRACY DYPLOMOWEJ MAGISTERSKIEJ

IMPLEMENTACJA WYBRANYCH ALGORYTMÓW WYPEŁNIANIA BRAKUJĄCYCH WARTOŚCI, DLA STRUMIENI DUŻYCH ZBIORÓW DANYCH

Autor: inż. Krzysztof Lang, nr albumu: EF-148853
Opiekun: dr Michał Piętal
Słowa kluczowe: bazy danych, brakujące wartości, wypełnianie, duże zbiory danych

Dla poprawnej analizy danych ważna jest jej kompletność. Istnieje wiele sposobów radzenia sobie z brakującymi danymi. Najprostsze metody opierające się między innymi na średniej bądź najczęściej występującej wartości w wielu przypadkach mogą negatywnie wpłynąć na skuteczność analizy. Niniejsza praca ma na celu przeanalizować skuteczność uzupełniania brakujących danych z użyciem bardziej zaawansowanych metod opierających się na wykorzystaniu uczenia maszynowego. Te metody mają na celu wypełnić brakujące dane wartościami dużo bardziej zbliżonymi do rzeczywistych, minimalizując negatywny wpływ na skuteczność późniejszej analizy danych.

RZESZOW UNIVERSITY OF TECHNOLOGY Rzeszow, 2023
Faculty of Electrical and Computer Engineering

MSC THESIS ABSTRACT

IMPLEMETATION OF SELECTED MISSING VALUE IMPUTATION ALGORITHMS FOR LARGE DATA SETS

Author: Krzysztof Lang, BSc, code: EF-148853
Supervisor: Michał Piętal, PhD
Key words: databases, missing values, imputation, big data

For correct data analysis, completeness is important. There are many ways to deal with missing data. The simplest methods based on, among other things, the average or the most frequently occurring value in many cases can negatively affect the effectiveness of the analysis. This thesis aims to analyze the effectiveness of imputing missing data using more advanced methods based on the use of machine learning. These methods are designed to impute missing data with values much closer to the actual data, minimizing the negative impact on the effectiveness of subsequent data analysis.