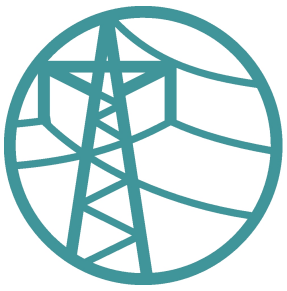

WYDZIAŁ
ELEKTROTECHNIKI
I INFORMATYKI
POLITECHNIKI RZESZOWSKIEJ

**inż. Krzysztof Lang**

# Implementacja wybranych algorytmów wypełniania brakujących wartości, dla strumieni dużych zbiorów danych

**Praca dyplomowa magisterska**

Opiekun pracy:
dr Michał Piętal

Rzeszów, 2023

# Spis treści

# 1. Wstęp

W pierwszym rozdziale przedstawiono zarys treści dalszej pracy. W drugim rozdziale przybliżono ideę wypełniania brakujących wartości w duzych zbiorach danych, na co składa się rys historyczny zagadnienia, przedstawienie istniejących rozwiązań i ich znaczenie, oraz zastanowiono się nad przyszłością zagadnmienia. Trzeci rozdział przybliża narzędzia użyte do przygotowania części praktycznej niniejszej pracy, to jest programu realizującego testy algorytmów wypełniajacych puste miejsca oraz dane wykorzystane do testów. Na rodział czwarty składa się opis praktycznej części badań. Znajduje się w nim opis przygotowanego programu wraz z przykładem działana, opisy zaimplementowanych algorytmów, oraz przedstawione zostały wyniki przeprowadzonych testów. Rozdział piąty składa się z podsumowania przeprowadzonych działań i przedstawienia wyciągniętych wniosków.

# 2. Wprowadzenie do wypełniania brakujących wartości

## 2.1. Rys historyczny

## 2.2. Na czym polega wypełnianie brakujących wartości

## 2.3. Korzyści i zagrożenia

## 2.4. Perspektywy na przyszłość

# 3. Omówienie narzędzi i danych

## 3.1. Python

Python to interpretowany język wysokiego poziomu o ogólnym zastosowaniu. Stworzony został w roku 1991 przez Guido van Rossum i jest wciąż wciąż rozwijany. Najnowsza stabilna wersja to 3.11.2.

Python znany jest ze swojej prostej do zrozumienia składni, czytelnego kodu, wsparcia różnych paradygmatów programowania (obiektowego, imperatywnego, funkcyjnego), dużej biblioteki standardowej i bardzo szerokiego wyboru dodatkowych bibliotek. [1]

Do słabszych stron języka zaliczyć można słabą wydajność pod względem prędkości działania i wykorzystania pamięci bądź problemy z kompatybilnością kodu napisanego w różnych wersjach lub implementacjach Pythona.

## 3.2. Visual Studio Code

Jako środowisko programowania wybrano "Microsoft Visual Studio Code". Jest to darmowy edytor kodu o otawrtym kodzie. Stworzony został przez firmę Microsoft w roku 2015. Zaprojektowany został z myślą tworzenia nowoczesnych aplikacji webowych i chmurowych z wykorzystaniem wielu języków. [2] Ze względu na otwartość kodu, dostępne jest wiele rozszerzeń do programu, które znacznie ułatwiają tworzenie nawet skomplikowanych projektów.

W celu umożliwienia pracy nad programem z wielu urządzeń oraz dla zachowania pełnej historii tworzenia programu wykorzystano integrację "Visual Studio Code"z repozytorium GitHub.

## 3.3. Biblioteki

### 3.3.1. Pandas

Pandas to popularna biblioteka służąca manipulacji i analizy danych w Pythonie. Stworzona została w roku 2008 przez Wesa McKinney i jest stale rozwijana przez dużą grupę deweloperów. Nazwa Pandas pochodzi od "Python data analysis". Najważniejsze zalety Pandas to:

- wsparcie dla wielu formatów danych, w tym CSV, Excel, SQL i inne,

- duża szybkość przeprowadzania operacji na danych,
- obsługa brakujących wartości w danych,
- łatwa integracja z innymi popularnymi bibliotekami,
- bardzo rozbudowana dokumentacja.

Pandas wykorzystuje dwie główne struktury danych: "Series"i "DataFrame". Ta pierwsza to jednowymiarowa tablica wartości posiadająca indeksy każdego elementu, z kolei druga to dwuwymiarowa tablica wartości z indeksami zarówno rzędów jak i kolumn. Obydwie struktury mogą przechowywać dowolne typy danych. [3]

### 3.3.2. NumPy

NumPy to biblioteka dla Pythona wykorzystywana do pracy na obiektach będących wielowymiarowymi tablicami oraz udostęniajaca szereg narzędzi do obliczeń naukowych. Została stworzona w roku 2005 przez Travisa Oliphant jako następca bibliotek Numeric [4] i Numarray [5]. Biblioteka jest wciąż rozwijana przez zaangażowaną grupę programistów. NumPy jest szeroko wykorzystywana do przeprowadzania obliczeń naukowych ze względu na szereg zalet:

- wspiera wielowymiarowe tabele, zarówno o homogenicznych jak i heterogenicznych typach danych,
- oferuje dużą ilość funkcji matematycznych, generatorów liczb pseudolosowych, transformat i innych narzędzi przydatnych w zastosowaniach naukowych,
- łatwo integruje się z innymi bibliotekami,
- posiada bardzo rozbudowaną dokumentację.

Do wad zaliczają się stosunkowo niska wydajność i problemy z obsługą niektórych typów danych i brakujących wartości. [6]

### 3.3.3. SciEKit-learn

SciKit-learn to biblioteka zawierająca narzędzia związane z uczeniem maszynowym dla Pythona. Jest częścią większego zestawu narzędzi SciKit, zawierającego biblioteki oferujące szeroki wachlarz narzędzi do analizy danych. Początkowo stworzony przez Davida Cournapeau jako projekt w ramach "Google Summer of Code"w

roku 2007, został później przepisany i rozwinięty głównie przez Francuski Instytut Badań w Dziedzinie Informatyki i Automatyki (INRIA) i udostępniony publicznie w roku 2010. SciKit-learn przestrzega zasad projektowania API dla oprogramowania uczenia maszynowego, które obejmują między innymi spójność, rozsądne domyślne ustawienia i dokumentację. [7]

### 3.3.4. EasyGUI

EasyGUI to biblioteka Pythona służaca do implementacji prostego interfejsu graficznego. Został stworzony przez Stephena Ferg i udostęniony w roku 2004. Oparty jest na bibliotece Tkinter [8]. Główną zaletą EasyGUI jest jego prosta składnia, pozwalajaca na tworzenie nieskomplikowanych aplikacji bez konieczności uczenia się stosowania bardziej zaawansowanych bibliotek. Osiągnięte to zostało przez zastosowanie predefiniowanych okien spełniających najczęściej wykorzystywane role, taklie jak okna wyboru, wyświetlanie wiadomości, wpisywanie tekstu i inne. Niestety zaprzestano dalszego rozwoju biblioteki, przez co nie można spodziewać się dodania nowych funkcji czy popraw działania istniejących. [9]

## 3.4. Źródła danych

### 3.4.1. Użyte repozytoria danych

Aby wyniki badań niosły ze sobą odpowiednią wartość merytoryczną, potrzebne są odpowiednie zbiory danych na których zostaną przeprowadzone testy. W celu znalezienia odpowiednich zbiorów danych, przyjęto następujące założenia:

- zbiór danych musi być wystarczająco duży,
- zbiór danych musi zawierać odpowiedniż ilość atrybutów aby modele decyzyjne miały do dyspozycji wystarczającą ilość danych uczących,
- atrybuty powinny zawierać różnorodne typy danych w celu przetestowania wypełniania zarówno danych liczbowych (całkowitych i zmiennoprzecinkowych) jak i kategorycznych,
- zbiór danych nie może mieć pustych wartości.

Do wyszukania odpowiednich zbiorów danych wykorzystano narzędzie "Google Dataset Search". Z jego pomocą wybrano 2 zbiory danych z różnych dziedzin. Po

uprzedniej ich obróbce zostały wykorzystane do przeprowadzenia testów algorytów wypełniania.

### 3.4.2. Adult Data Set

Zbiór danych "Adult Data Set"zawiera dane ze spisu ludności przeprowadzonego w roku 1994 w Stanach Zjednoczonych. Jest szeroko wykorzystywany do testowania uczenia maszynowego. Zawiera ponad 30000 rekordów i 15 atrybutów. [10] Opis atrybutów:

- age: wiek spisanej osoby, liczba całkowita,
- workclass: rodzaj zatrudnienia, dane kategoryczne, 8 możliwych wartości,
- fnlwgt: jaka proporcja populacji ma identyczny zestaw pozostałych wartości, liczba całkowita,
- education: osiągnięty poziom edukacji, dane kategoryczne, 16 możliwych wartości,
- education-num: osiągnięty poziom edukacji zakodowany jako liczba całkowita,
- martial-status: status matrymonialny, dane kategoryczne, 7 możliwych wartości,
- occupation: zawód, dane kategoryczne, 14 możliwych wartości,
- relationship: rola w związku, dane kategoryczne, 6 możliwych wartości,
- race: klasyfikacja rasowa, dane kategoryczne, 5 możliwych wartości,
- sex: płeć, dane kategoryczne, 2 możliwe wartości,
- capital-gain: zysk kapitału w zwiazku z inwestycjami, liczba całkowita,
- capital-gain: strata kapitału w zwiazku z inwestycjami, liczba całkowita,
- hours-per-week: ilość godzin pracujących w tygodniu, liczba całkowita,
- native-country: kraj pochodzenia, dane kategoryczne, 41 możliwych wartości,
- attribute: czy osoba zarabia powyżej czy poniżej 50000$ rocznie.

Ten zbiór danych został wybrany ze względu na występowanie zarówno atrybutów liczbowych jak i kategorycznych, zadowalajacą ilość rekordów oraz atrybutów. Ma na celu przetestowanie skuteczności działania algorytmów do wypełniania brakujących miejsc w zbiorach danych z brakami w danych o różnych typach. Nie wymaga dodatkowej obróbki przed rozpoczęciem testów.

### 3.4.3. Stock Exchange Data

Zbiór danych "Stock Exchange Data"zawiera informacje o cenach akcji na giełdach w różnych krajach w latach 1965-2021. Dane zostały zebrane z "Yahoo Finance", posiadającego dane o giełdzie z wielu lat w wielu krajach. Posiada ponad 100000 rekordów i 9 atrybutów. [11] Opis atrybutów:

- Index: symbol wskazujacy z jakiej giełdy pochodzą dane, dane kategoryczne, 5 możliwych wartości,
- Date: data obserwacji, dane kategoryczne,
- Open: cena akcji podczas otwarcia, liczba wymierna,
- High: najwyższa cena w ciągu dnia, liczba wymierna,
- Low: najniższa cena w ciągu dnia, liczba wymierna,
- Close: cena akcji w momencie zamknięcia, liczba wymierna,
- Adj Close: cena akcji w momencie zamknięcia skorygowana o podziały jak i dywidendy, liczba wymierna,
- Volume: liczba akcji będących przedmiotem obrotu w ciągu dnia sesyjnego, liczba całkowita,
- CloseUSD: cana akcji w momencie zamknięcia wyrażona w dolarach amerykańskich

Ten zbiór danych został wybrany ze względu na bardzo popularną kategorię danych, to jest dane finansowe. Ma na celu przetestowanie skuteczności działania algorytmów w przypadku danych numerycznych, w szegółności liczb wymiernych. W celu lepszego przygotowania do testów zakodowano kolumnę "Data"z wykorzystaniem "label encoding", to jest zamiany danych na postać numeryczną. Usunięto też rekordy posiadające wartość "0"w kolumnie "Volume". Ich duża ilość (ponad 30%) mogła by negatywnie

wpłynąć na uczenie modeli decyzyjnych. W wyniku tego zmniejszono liczbę rekordów do ponad 62000, co wciąż jest ilością spełniajacą założenia dla zbiorów danych.

# 4. Implementacja i testy

## 4.1. Opis przygotowanego programu

### 4.1.1. Założenia i realizacja

Założono, że program ma rtealizować 3 zadania:

1) Przygotować dane do wypełniania poprzez sztuczne utworzenie brakujacych wartości.

2) Wypełnić brakujące wartości z wykorzystaniem wybranych algorytmów.

3) Ocenić skuteczność wypełniania w celu porównania algorytmów.

Poszczególne zadania zrealizowano jako osobne moduły.
Przyjęto też następujące założenia:

1) Wykorzystanym językiem ma być Python.

2) Program ma być napisany zgodnie z paradygmatem programowania obiektowego.

3) Poszczególne klasy mają być zawarte w osobnych plikach.

4) Interakcja z programem ma opierać się o prosty interfejs graficzny.

5) Dostęp do wszystkich modułów programu ma być zapewniony z jednego miejsca.

6) Pliki wygenerowane przez jeden moduł mają być przygotowane w sposób umożliwiający wykorzystanie ich przez kolejny. Oprócz odpowiedniego formatowania wewnątrz pliku, oznacza to przyjęcie konwencji nazewnictwa plików opartej o prefiksy i sufiksy.

Program składa się z następujacych plików:

- mgr_main.py: główny plik nie zawierający żadnej klasy, odpowiadający za wybór modułu do uruchomienia, i uruchomienie odpowiedniego modułu po wybraniu,

- mgr_nan_gen"plik zawierajacy klasę "NanGen", odpowiadającą za realizację modułu przygotowujacego plik,

- mgr_fill.py: plik zawierający klasę "Fill", odpowiadającą za realizację modułu wypełniajacego brakujące dane,

- mgr_data.py: plik zawierający klasę "Data", odpowiadającą za wybranie pliku do wypełnienia i przygotowanie do do dalszej obróbki, oraz klasę "PrepareData", odpowiadającą za przygotowanie danych do przekazania silnikowi uczenia maszynowego celem wypełnienia oraz późniejszemu przywróceniu danym ich pierwotnego wyglądu

- mgr_di.py: plik zawierjący klasę DownImpu, odpowiadającą za przygotowanie danych dla algorytmu "Downward Imputation"

- mgr_temp_fill: plik zawierający klasę "TempFill", odpowiadającą za tymczasowe wypełnianie brakujących miejsc, potrzebne podczas przygotowywania danych dla algorytmu "Prostego"

- mgr_acc: plik zawierający klasę "AccuracyTester", odpowiadającą za obliczanie skuteczności wypełniania danych

Wykorzystując narzędzie "auto-py-to-exe", utworzono plik "mgr_suite.exe", pozwalajacy uruchomić program bez konieczności instalowania interpretera Python i potrzebnych bibliotek. [12]

### 4.1.2. Działanie programu

Poniżej zaprezentowano działanie programu na przykładzie pliku data_stock.csv. Zostanie on najpierw przygotowany do testów, następnie brakujace dane zostaną wypełnione z wykorzystaniem jednego z algorytmów, po czym zostanie obliczona dokładność tego wypełnienia.

Po uruchomieniu "mgr_suite.exe"wyświetlone zostaje okno służące do wyboru modułu, pokazane na rysunku 4.1.

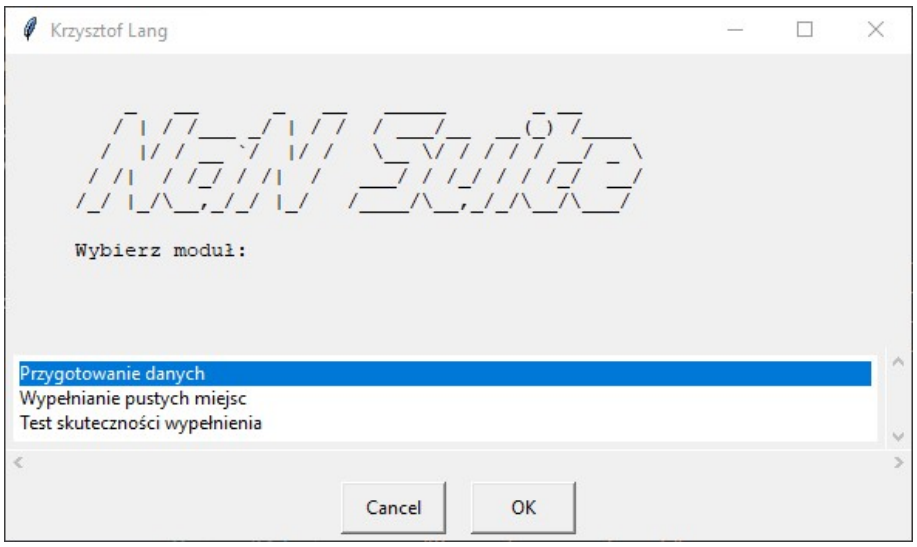


Rysunek 4.1: Główne okno programu, pozwalajace na wybór modułu do uruchomienia

Pierwszy moduł odpowiada za przygotowanie danych do wypełniania poprzez usunięcie losowych wartości ze zbioru danych. Pierwszym krokiem jest wybranie pliku który ma zostać przygotowany z użyciem okna pokazanego na rysunku 4.2. Lista plików generowana jest na podstawie plików znajdujących się w tym samym folderze co uruchamiany program spełniających założony format nazwy. Założono, że pliki które nadają się do wypełnienia mają być zapisane w formacie CSV, natomiast nazwa zaczynać się ma od prefiksu "data_"i nie posiadać żadnych sufiksów.

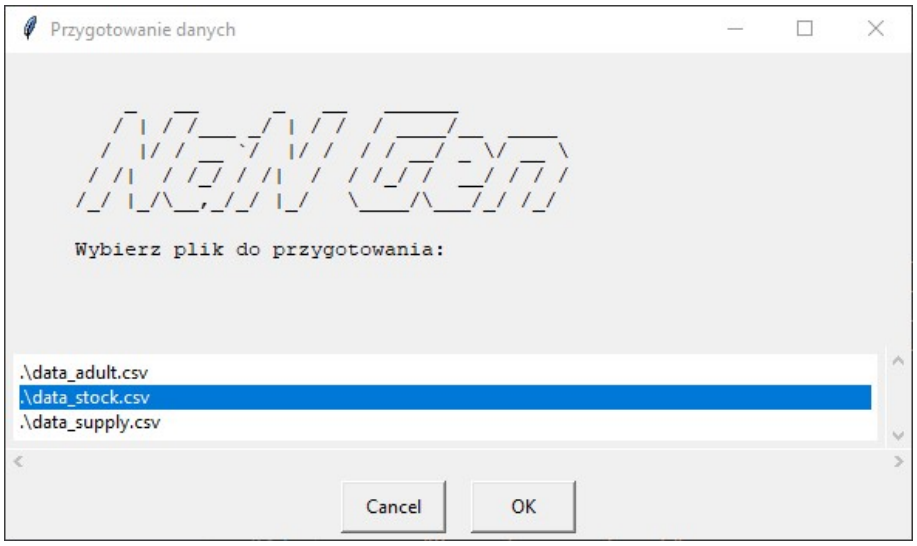


Rysunek 4.2: Okno wyboru pliku do przygotowania

Następnie wybrane z listy zostają kolumny w których maja zostać usunięte dane.

Wyboru dokonuje się z użyciem okna pokazanego na rysunku 4.3. Kolumny do wyboru zaczerpnięte są bezpośrednio z załadowanego wcześniej pliku. Wybrać można dowolną ilość, lecz zalecane jest poniżej 50%.

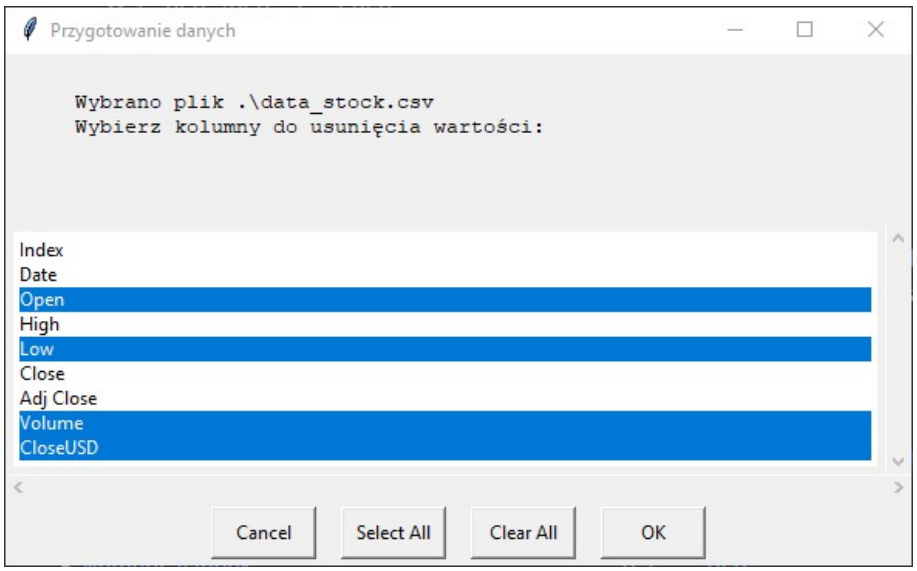


Rysunek 4.3: Okno wyboru kolumn

W wybranych kolumnach zostaje usunięte od 5% do 15% wartości - dla każdej kolumny ilość jest losowana. Dodatkowo stworzony zostaje plik przechowujęcy informacje które wartości zostały usunięte. Ta informacja zostaje później wykorzystana do oceny skuteczności wypełnienia zbioru danych. Po zakończeniu usuwania wartości wyświetlone zostaje okno z podsumowaniem jak na rysunku 4.4. Nazwa utworzonego pliku z gotowymi danymi tworzona jest poprzez dodanie sufiksu "_holes_X"do nazwy oryginalnego pliku, gdzie X to kolejna liczba naturalna. Umożliwia to tworzenie plików z danymi usuniętymi z różnych zestawów kolumn bez konieczności ręcznej zmiany ich nazw. Nazwa pliku z informacją które dane zostały usunięte tworzona jest przez dodanie sufiksu "_journal"do nazwy oryginalnego pliku.

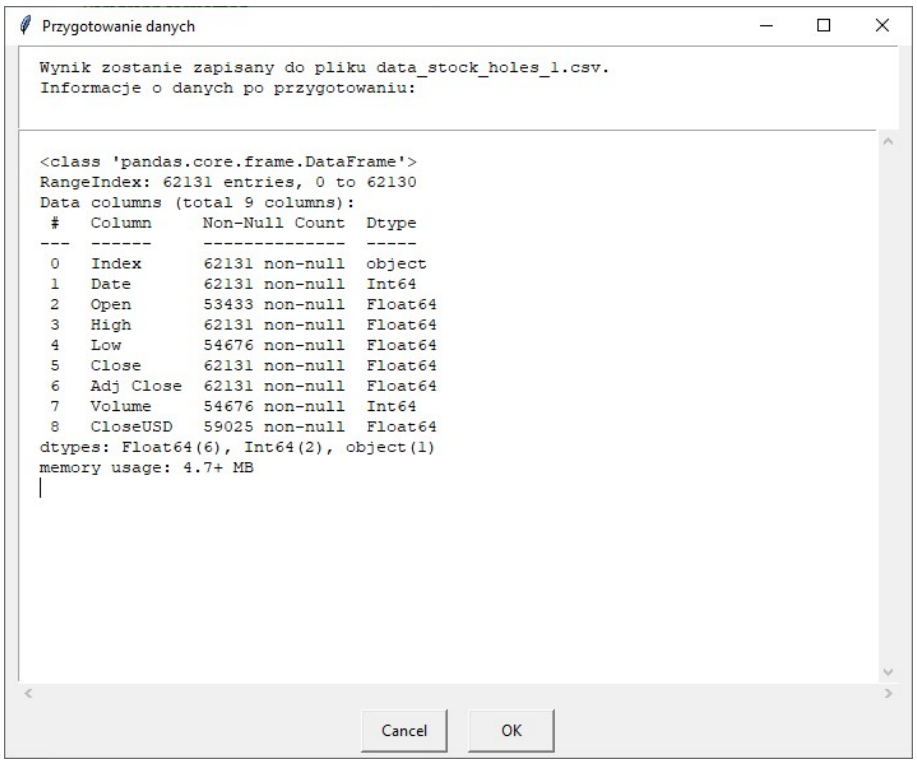


Rysunek 4.4: Okno z podsumowaniem

Drugi moduł służy do wypełniania brakujacych wartości w zbiorze danych z użyciem wybranego algorytmu.

Najpierw należy wskazać plik który ma zostać wypełniony z użyciem okna wyboru pokazanego na rysunku 4.5. Tak jak wcześniej, lista tworzona jest na podstawie plików w folderze i przyjętej konwencji nazewnictwa plików. Wyświetlane są wyłącznie pliki posiadające sufiks "_holes_X"w nazwie, bez kolejnych sufiksów.

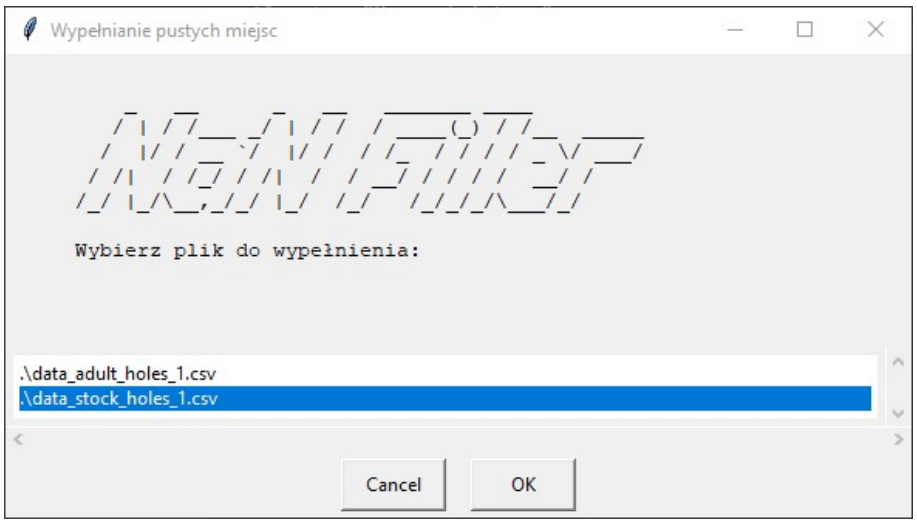


Rysunek 4.5: Okno wyboru pliku do wypełnienia

Następnie z użyciem okna jak na rysunku 4.6 wybrany zostaje algorytm który ma zostać wykorzystany do wypełniania brakujących wartości. Wyświetlona zostaje też nazwa wybranego wcześniej pliku w celu uniknięcia błędu wybrania niewłaściwego pliku.

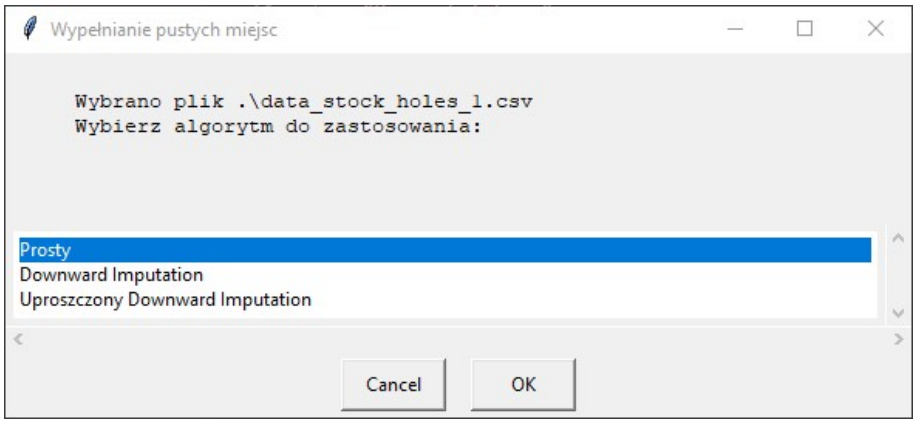


Rysunek 4.6: Okno wyboru algorytmu

Puste miejsca zostają wypełnione z wykorzystaniem wybranego algorytmu. Dokładny sposób działania algorytmów zostanie opisany w kolejnych rozdziałach. Po zakończeniu wypełniania wyświetlone zostaje podsumowanie jak na rysunku 4.7. Nazwa pliku wynikowego tworzona jest poprzez dodanie sufixu "_filled_Y", gdzie Y to nazwa wybranego algorytmu.

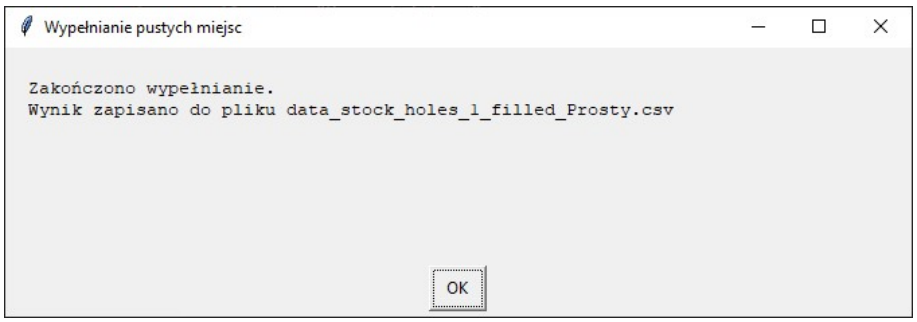


Rysunek 4.7: Okno z podsumowaniem wypełniania

Ostatni moduł odpowiada za wygenerowanie danych, które można wykorzystać do oceny skuteczności wypełniania brakujących wartości. Jako wystarczające uznano procent skuteczności wypełniania dla danych kategorycznych i liczb całkowitych oraz średnie odchylenie bezwzględne dla wszystkich danych liczbowych. Obie wartości są obliczane dla poszczególnych wypełnionych kolumn.

Jak w przypadku poprzednich modułów, zacząć należy od wyboru pliku który ma zostać poddany analizie. Wyboru dokonuje się z użyciem okna pokazanego na rysunku 4.8. Wyświetlane są tylko pliki zawierające słowo "filled"w nazwie, ponieważ takie pliki posiadają wartości wypełnione za pomocą któregoś algorytmu z użyciem odpowiedniego modułu.

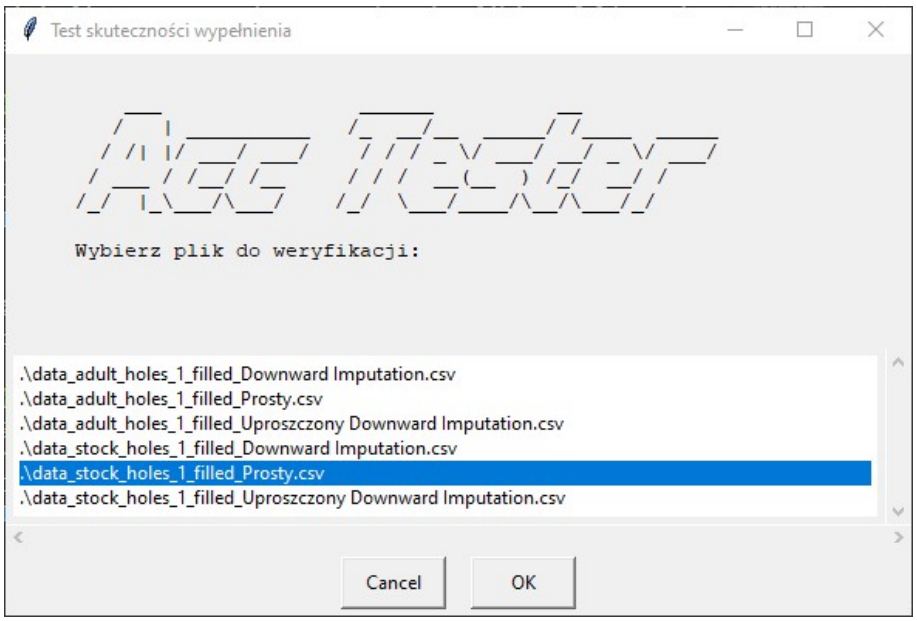


Rysunek 4.8: Okno wyboru pliku do analizy

Z użyciem wybranego pliku, oryginalnego pliku z danymi przed usunięciem losowych danych oraz pliku z informacją które dane zostały usunięte a następnie wypełnione, przeprowadzane jest obliczanie skuteczności wypełniania danych.

Obliczenie procentowej skuteczności wypełnienia przebiega następująco:

1) Sprawdzenie ilości wypełnianych wartości w danej kolumnie.

2) Zsumowanie ilości poprawnie wypełnionych danych w kolumnie poprzez porównanie wartości o współrzędnych zapisanych w pliku tworzonym podczas przygotowywania danych.

3) Zastosować wzór 4.1:

$$ACC = \frac{m}{n} \times 100\% \tag{4.1}$$

gdzie: $ACC$ – procentowa skuteczność wypełnienia kolumny, $m$ – ilość poprawnie wypełnionych wartości, $n$ – ilość wypełnionych wartości.

Aby obliczyć średnie odchylenie bezwzględne należy zastosować wzór 4.2:

$$AAD = \frac{\sum_{i=1}^{n} |x_i - \hat{x_i}|}{n} \tag{4.2}$$

gdzie: $AAD$ – średnie odchylenie bezwzględne dla danej kolumny, $n$ – ilość wypełnionych wartości w kolumnie, $x_i$ – wartość wypełnionego $i$-tego elementu kolumny, $\hat{x_i}$ – oryginalna wartość $i$-tego elementu kolumny.

Po zakończeniu obliczeń, wyświetlane jest podsumowanie jak na rysunku 4.9, a wynik obliczeń zapisywany jest w dwóch plikach

- wyniki obliczania procentowej skuteczności jest zapisywany w pliku o nazwie tworzonej przez dodanie do nazwy analizowanego pliku sufiksu "_aad",

- wyniki obliczania średniego odchylenia bezwzględnego jest zapisywany w pliku o nazwie tworzonej przez dodanie do nazwy analizowanego pliku sufiksu "_acc".


Rysunek 4.9: Okno z podsumowaniem

## 4.2. Opis implementacji algorytmów

Implementowane algorytmy opierają się o kolejne rozwinięcia idei zaprezentowanej przez Piętal M. w [13]. Polega ona na sformułowaniu problemu wypełniania problemu wypełniania brakujących wartości jako problemu decyzyjnego. Wynikają z tego następujące założenia:

- kolumny wypełniane są pojedyńczo,
- samo wypełnianie przeprowadzane jest przez system decycyjny,
- algorytm ma za zadanie wybrać kolejność wypełniania kolumn oraz określić jakie kolumny będą zawarte w zbiorze danych uczących systemu decyzyjnego.

Działanie poszczególnych algorytmów zostanie zaprezentowane na przykładowej tabeli 4.1 przedstawiającej zbiór danych:

Tabela 4.1: Tabela wyjściowa

| | A | B | C | D | E | F | G | H | I | J | K | L | M | N |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | * | * | x | * | * | * | x | * | * | * | x | * | * | * |
| 2 | x | * | * | * | * | * | * | * | * | * | * | x | * | * |
| 3 | * | * | * | * | x | * | * | * | * | * | * | x | * | * |
| 4 | x | * | x | * | x | * | x | x | * | * | x | x | * | * |
| 5 | * | * | * | * | x | * | * | x | x | * | * | * | * | * |
| 6 | * | * | * | * | x | * | x | x | * | * | * | * | * | * |
| 7 | * | * | * | * | x | * | * | * | * | * | * | * | * | * |
| 8 | * | * | * | * | * | * | * | x | * | * | x | * | x | * |
| 9 | * | * | * | * | x | * | * | * | x | * | * | * | x | * |
| 10 | * | * | * | * | * | * | x | * | x | * | * | * | * | * |
| 11 | * | x | * | * | x | * | * | * | * | * | * | * | * | * |

gdzie: $*$ – istniejąca wartość, $x$ – brakująca wartość.

### 4.2.1. Prosty

Procedura dla algorytmu prostego wygląda następująco:

1) Tworzony jest zbiór kolumn z brakującymi wartościami $X$. Dla przykładowej tabeli będzie to zbiór $X = \{A, B, C, E, G, H, I, K, L, M\}$.

2) Kolumny w zbiorze $X$ są następnie sortowane od kolumn zawierających najmniejszą ilość brakujących wartości do zawierających ich najwięcej, dając ciąg $\eta$. W przypadku kolumn o takiej samej ilości brakujących danych kolejność nie ma znaczenia. Dla przykładowej tabeli zbiór ten będzie wyglądał następująco: $\eta = (B, M, C, A, L, K, I, H, G, E)$.

3) Pierwszy element w ciągu $\eta$ zostaje wybrany jako kolumna która zostanie wypełniona. W przykładzie będzie to element $B$.

4) Tabela zostaje rozdzielona na dwie: w jednej znajdują się rekordy w których w kolumnie wybranej do wypełnienia znajdują się dane, a w drugiej rekordy w których w wybranej tabeli danych brakuje. Dla przykładowej tabeli będzie to wyglądało następująco, gdzie tabela 4.2 przedstawia tabelę z danymi w wybranej

kolumnie, natomiast tabela 4.3 przedstawia tabelę z brakiem danych w wybranej kolumnie. Dla lepszej czytelności, przesunięto rozważaną kolumnę na początek tabeli:

Tabela 4.2: Tabela wydzielona z oryginalnej, zawierająca wyłacznie rekordy z danymi w rozważanej kolumnie

| | A | B | C | D | E | F | G | H | I | J | K | L | M | N |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | * | * | x | * | * | * | x | * | * | * | x | * | * | * |
| 2 | x | * | * | * | * | * | * | * | * | * | * | x | * | * |
| 3 | * | * | * | * | x | * | * | * | * | * | * | x | * | * |
| 4 | x | * | x | * | x | * | x | x | * | * | x | x | * | * |
| 5 | * | * | * | * | x | * | * | x | x | * | * | * | * | * |
| 6 | * | * | * | * | x | * | x | x | * | * | * | * | * | * |
| 7 | * | * | * | * | x | * | * | * | * | * | * | * | * | * |
| 8 | * | * | * | * | * | * | * | x | * | * | x | * | x | * |
| 9 | * | * | * | * | x | * | * | * | x | * | * | * | x | * |
| 10 | * | * | * | * | * | * | x | * | x | * | * | * | * | * |

Tabela 4.3: Tabela wydzielona z oryginalnej, zawierająca wyłacznie rekordy z brakiem danych w rozważanej kolumnie

| | A | B | C | D | E | F | G | H | I | J | K | L | M | N |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 11 | * | x | * | * | x | * | * | * | * | * | * | * | * | * |

5) Pierwsza z tabel - w przykładzie tabela 4.2 - posłuży do uczenia modelu uczenia maszynowego. Wypełniana kolumna służy jako cel, a pozostałe jako dane uczące.

6) Następnie nauczony model zostaje wykorzystany do wypełnienia brakujących wartości w drugiej tabeli, w przykładzie tabeli 4.3.

7) Na koniec tabele są łączone w jedną co w przykładzie poskutkuje tabelą 4.4, a algorytm jest powtarzany aż do wypełnienia wszystkich brakujących wartości.

Tabela 4.4: Tabela prezentująca wygląd danych po pojedynczym przejściu algorytmu

| | A | B | C | D | E | F | G | H | I | J | K | L | M | N |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | * | * | x | * | * | * | x | * | * | * | x | * | * | * |
| 2 | x | * | * | * | * | * | * | * | * | * | * | x | * | * |
| 3 | * | * | * | * | x | * | * | * | * | * | * | x | * | * |
| 4 | x | * | x | * | x | * | x | x | * | * | x | x | * | * |
| 5 | * | * | * | * | x | * | * | x | x | * | * | * | * | * |
| 6 | * | * | * | * | x | * | x | x | * | * | * | * | * | * |
| 7 | * | * | * | * | x | * | * | * | * | * | * | * | * | * |
| 8 | * | * | * | * | * | * | * | x | * | * | x | * | x | * |
| 9 | * | * | * | * | x | * | * | * | x | * | * | * | x | * |
| 10 | * | * | * | * | * | * | x | * | x | * | * | * | * | * |
| 11 | * | * | * | * | x | * | * | * | * | * | * | * | * | * |

#### 4.2.2. Uproszczony Downward Imputation

#### 4.2.3. Downward Imputation

## 4.3. Napotkane problemy

## 4.4. Testy algorytmów na wybranych źródłach danych

# 5. Podsumowanie i wnioski końcowe

# Załączniki

# Literatura


[1] https://www.python.org/. Dostęp 26.02.2023.

[2] https://code.visualstudio.com/. Dostęp 26.02.2023.

[3] https://pandas.pydata.org/. Dostęp 26.02.2023.

[4] https://pypi.org/project/Numeric/. Dostęp 26.02.2023.

[5] https://pypi.org/project/numarray/. Dostęp 26.02.2023.

[6] https://numpy.org/. Dostęp 26.02.2023.

[7] https://scikit-learn.org/stable/. Dostęp 26.02.2023.

[8] https://docs.python.org/3/library/tkinter.html. Dostęp 26.02.2023.

[9] https://easygui.sourceforge.net/. Dostęp 26.02.2023.

[10] https://archive-beta.ics.uci.edu/dataset/2/adult. Dostęp 26.02.2023.

[11] www.kaggle.com/datasets/mattiuzc/stock-exchange-data. Dostęp 26.02.2023.

[12] https://pypi.org/project/auto-py-to-exe/. Dostęp 26.02.2023.

[13] Brański A.: Wybrane zagadnienia informatyki stosowanej. Oficyna Wydawnicza Politechniki Rzeszowskiej, Rzeszów 2020.

POLITECHNIKA RZESZOWSKA im. I. Łukasiewicza Rzeszów, 2023
Wydział Elektrotechniki i Informatyki

## STRESZCZENIE PRACY DYPLOMOWEJ MAGISTERSKIEJ

## IMPLEMENTACJA WYBRANYCH ALGORYTMÓW WYPEŁNIANIA BRAKUJĄCYCH WARTOŚCI, DLA STRUMIENI DUŻYCH ZBIORÓW DANYCH

Autor: inż. Krzysztof Lang, nr albumu: EF-148853
Opiekun: dr Michał Piętal
Słowa kluczowe: bazy, danych, brakujące, wartości, wypełnianie

Dla poprawnej analizy danych ważna jest ich kompletność. Istnieje wiele sposobów radzenia sobie z brakującymi danymi. Najprostsze metody opierające się między innymi na średniej bądź najczęściej występującej wartości w wielu przypadkach mogą negatywnie wpłynąć na skuteczność analizy. Niniejsza praca ma na celu przeanalizować skuteczność uzupełniania brakujących danych z użyciem bardziej zaawansowanych metod opierających się na wykorzystaniu uczenia maszynowego. Te metody mają na celu wypełnić brakujące dane wartościami dużo bardziej zbliżonymi do rzeczywistych, minimalizując negatywny wpływ na skuteczność późniejszej analizy danych.

RZESZOW UNIVERSITY OF TECHNOLOGY Rzeszow, 2023
Faculty of Electrical and Computer Engineering

## MSC THESIS ABSTRACT

## IMPLEMETATION OF SELECTED MISSING VALUE FILLING ALGORITHMS FOR LARGE DATA SETS

Author: Krzysztof Lang, BSc, code: EF-148853
Supervisor: Michał Piętal, PhD
Key words: databases, missing, values, filling

For correct data analysis, completeness is important. There are many ways to deal with missing data. The simplest methods based on, among other things, nthe average or the most frequently occurring value in many cases can negatively affect the effectiveness of the analysis. This paper aims to analyze the effectiveness of filling in missing data using more advanced methods based on the use of machine learning. These methods are designed to fill in missing data with values much closer to the actual data, minimizing the negative impact on the effectiveness of subsequent data analysis.